



Pós-Graduação em Ciência da Computação

Verificação de Assinaturas *Off-line* utilizando o Coeficiente de Correlação de Pearson

DAVI DELGADO CLEROT

DISSERTAÇÃO DE MESTRADO



Universidade Federal de Pernambuco
posgraduacao@cin.ufpe.br
www.cin.ufpe.br/~posgraduacao

RECIFE

Abril 2014



UNIVERSIDADE FEDERAL DE PERNAMBUCO
CENTRO DE INFORMÁTICA
PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

DAVI DELGADO CLEROT

Verificação de Assinaturas *Off-line* utilizando o Coeficiente de Correlação de Pearson

Dissertação apresentada como requisito parcial para a obtenção do título de Mestre pelo Programa de Pós-Graduação em Ciência da Computação do Centro de Informática da Universidade Federal de Pernambuco.

Orientador: Prof. Dr. Cleber Zanchettin

RECIFE

Abril 2014

DAVI DELGADO CLEROT

Verificação de Assinaturas *Off-line* utilizando o Coeficiente de Correlação de Pearson

Dissertação apresentada como requisito parcial para a obtenção do título de Mestre pelo Programa de Pós-Graduação em Ciência da Computação do Centro de Informática da Universidade Federal de Pernambuco.

Aprovado em: Abril 28, 2014

BANCA EXAMINADORA

Prof. Dr. Cleber Zanchettin - UFPE

Prof. Dr. Leandro Maciel Almeida - UFPE

Prof. Dr. Byron Leite Bezerra - UPE

RECIFE

Dedico este trabalho à minha esposa, que durante este projeto esteve comigo em todos os momentos, fossem eles fáceis ou difíceis.

Agradecimentos

*“Há uma força motriz mais poderosa
que o vapor, a eletricidade e a
energia atômica: a vontade.”*

Albert Einstein

Resumo

No âmbito da biometria comportamental, o reconhecimento automático de assinaturas manuscritas *off-line* se destacam pela boa aceitação em diversos segmentos, tais como Bancos, Cartórios e Imobiliárias. Dentre os fatores que estimulam sua utilização estão a facilidade na aquisição, pois não depende de equipamentos específicos, e seu valor legal ao ser realizada de próprio punho. No intuito de investigar métodos alternativos para realizar sua verificação automática, esta dissertação testa uma abordagem baseada no Coeficiente de Correlação de Pearson. O experimento foi realizado em seis etapas; da primeira à terceira, são utilizadas variações na extração de características, sem o auxílio de um classificador baseado em aprendizado automático. No quarto experimento, foi utilizada uma rede neural artificial como classificador, para efeito de comparação com os resultados anteriores. No quinto experimento, um peso associado ao limiar de resposta utilizado nos experimentos anteriores foi adicionado objetivando minimizar efeitos dos falsos positivos obtidos. No sexto e último experimento, para efeito de comparação com trabalhos relacionados, foi utilizada a base de dados disponibilizada no ICDAR 2011. A configuração empregada nesta etapa foi a do melhor experimento realizado dentre os anteriores. Os métodos propostos apresentaram resultados promissores em comparação com os resultados apresentados na literatura.

Palavras-chave: Verificação de assinaturas *off-line*, Reconhecimento de Padrões, Coeficiente de Correlação de Pearson

Abstract

In the field of behavioral biometrics, automatic off-line handwritten signature recognition stands out for its widespread acceptance in different market segments, such as Banks, Civil Registry Offices and Real State Agencies. Among the reasons why its use is widely stimulated are its ease of acquisition, once it does not depend on specific equipment, and its legal value when it is done by the author's own handwriting. With the purpose of searching for alternative methods to proceed to its automatic verification, this essay tests out an approach based on Pearson Correlation Coefficient. The experiment was carried out through six steps; from the first to the third ones, there were used variations for feature extraction, without the assistance of a learning classifier. In the fourth experiment, there was used an artificial neural network as a classifier, in order to compare its results with those obtained in the previous tests. In the fifth experiment, a weight associated to the threshold results obtained in the previous experiments was added, so as to minimize the false positive rate. In the sixth and last experiment, for comparison with related essays, there was used the ICDAR 2011 database. The configuration utilized in this last step was the one obtained in the best test among the previous ones. The proposed methods presented promising results compared to others reported in the literature.

Keywords: Offline Signature Verification, Pattern Recognition, Pearson Correlation Coefficients

Sumário

Sumário.....	x
Lista de Figuras.....	xii
Lista de Tabelas	xiv
Lista de Abreviações	xv
1. Introdução	1
1.1 Motivação	2
1.2 Objetivo	3
1.3 Organização da dissertação	4
2. Verificação de Assinaturas Manuscritas	5
2.1 Tipos de Falsificações	8
2.2 Assinaturas <i>On-line</i> e <i>Off-line</i>	10
2.3 Verificação <i>versus</i> Reconhecimento	11
2.4 Medidas de Desempenho.....	12
2.5 Trabalhos Relacionados.....	14
3. Materiais e Métodos.....	17
3.1 Aquisição da Base de Assinaturas	17
3.1.1 Base de Dados I.....	17
3.1.2 Base de Dados II.....	20
3.2 Pré-Processamento.....	21
3.3 Extração das Características.....	22
3.3.1 Características Periféricas e Diferenciais Periféricos	23
3.3.2 Segmentação	24
3.4 Coeficiente de Correlação de Pearson.....	25
3.4.1 Definição de Limiares.....	26
3.5 Redes Neurais Artificiais	28
3.6 Curva ROC.....	30
3.6.1 Área Abaixo da Curva ROC (AUC)	34
4. Experimentos	37
4.1 Modelos Propostos.....	37
4.1.1 Primeiro Experimento.....	39
4.1.2 Segundo Experimento.....	41
4.1.3 Terceiro Experimento	42
4.1.4 Quarto Experimento – RNA como Classificador.....	43
4.1.5 Quinto Experimento – Pesos Associados aos Limiares	46
4.1.6 Sexto Experimento – Utilizando a base do ICDAR2011.....	47

4.2 Comparação entre os Experimentos	48
5. Conclusão.....	57
5.1 Trabalhos Futuros	58
Referências	60

Lista de Figuras

Figura 1 - Diferença entre variação intrapessoal e interpessoal: (a) assinatura genuína; (b) variação intrapessoal; (c) variação interpessoal.	5
Figura 2 - Causas modificadoras da escrita. Adaptado de [MENDES, 2003].	6
Figura 3 - Fluxo padrão utilizado no processo de verificação de assinaturas <i>off-line</i> [SOUZA, 2009].	7
Figura 4 - Diagrama hierárquico das abordagens utilizadas no processo de verificação de assinaturas [Adaptado de MÉLO, 2011].	11
Figura 5 - Exemplo de um documento de assinaturas utilizando um Grid 5x2. 19	
Figura 6 - Exemplo de documento de assinaturas falsas.	20
Figura 7 - Exemplo de assinatura pré-processada.	22
Figura 8 - Segmentação da Imagem original e da região superior por intermédio de um grid de 10x20.	25
Figura 9 - Função de ativação Sigmoidal Logística.	29
Figura 10 - Matriz confusão [SOUZA, 2009].	31
Figura 11 - Gráfico ROC exibindo 5 classificadores discretos [adaptado de FAWCETT, 2004].	32
Figura 12 - Exemplo de Curva ROC para análise de dois classificadores discretos [adaptado de FAWCETT, 2004].	34
Figura 13 - AUC de dois classificadores A e B [adaptado de FAWCETT, 2004].	36
Figura 14 - Fluxo de execução utilizado nos experimentos 1, 2 e 3.	39
Figura 15 – Fluxo de execução utilizado no quarto experimento.	44
Figura 16 - Para o primeiro experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.	49
Figura 17 - Para o segundo experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.	50
Figura 18 - Para o terceiro experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.	51

Figura 19 - Curva ROC para o classificador utilizado no quarto experimento, no qual foi implementado uma RNA.....	52
Figura 20 - Para o quinto experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente, sendo na coluna da esquerda com ajuste do limiar para 5% de falsos positivos e na coluna da direita com ajuste para 10% de falsos positivos.....	53
Figura 21 - Comparativo entre os melhores casos dos experimentos realizados utilizando a base de dados I, no qual se destaca o primeiro experimento.	54
Figura 22 - Para o sexto experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente, utilizando a base de dados do ICDAR 2011.	55

Lista de Tabelas

Tabela 1 - Exemplo de uma assinatura de cada autor que participou do processo de captura.....	18
Tabela 2 - Exemplo de uma assinatura de cada autor que compôs a base disponibilizada no ICDAR 2011.....	21
Tabela 3 - Exemplo de CPDP baseado na Figura 7.....	23
Tabela 4 - Resultados do primeiro experimento.....	40
Tabela 5 - Resultados do segundo experimento.....	42
Tabela 6 - Resultados do terceiro experimento.....	43
Tabela 7 - Resultado das 27 simulações com conservação dos pesos.	45
Tabela 8 - Resultado do quarto experimento após ajuste das configurações da RNA.....	46
Tabela 9 - Resultado do quinto experimento.....	47
Tabela 10 - Resultado do sexto experimento.....	48
Tabela 11 - AUC (área abaixo da Curva ROC) dos experimentos realizados..	54
Tabela 12 - AUC dos classificadores do sexto experimento utilizando a base do ICDAR 2011.	56
Tabela 13 - Resultados da competição de verificação de assinaturas <i>off-line</i> realizada no ICDAR 2011 [Adaptado de LIWICKI, 2011].	56

Lista de Abreviações

AER	<i>Average Error Rate</i> (Taxa de Erro Médio)
AUC	<i>Area Under Curve</i>
CPDP	Características Periféricas e Diferenciais Periféricos
FAR	<i>False Acceptance Rate</i> (Taxas de Falsa Aceitação)
FN	Falso Negativo
FP	Falso Positivo
FRR	<i>False Rejection Rate</i> (Taxa de Falsa Rejeição)
HMM	<i>Hidden Model Markov</i>
ICDAR	<i>International Conference on Document Analysis and Recognition</i>
KNN	<i>k-nearest neighbors</i>
L1	Limiar Médio
L2	Limiar Mediana
L3	Limiar Média Mediana
LPDD	<i>Linear Programming Dissimilarity-data Description</i>
MLP	<i>Multi-Layer Perceptron</i>
OCR	<i>Optical Character Recognition</i>
RNA	Rede Neural Artificial
ROC	<i>Receiver Operating Characteristics</i>
SVDD	<i>Support Vector Data Description</i>
TAR	<i>True Acceptance Rate</i> (Taxa de Aceitação Verdadeira)
TRR	<i>True Rejection Rate</i> (Taxa de Rejeição Verdadeira)
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo

1. Introdução

No reconhecimento de indivíduos por intermédio de sistemas automatizados podem ser encontrados diversos estudos e formas distintas de se identificar pessoas. Dentre os trabalhos mais recentes, existem duas biometrias distintas que dividem as principais abordagens: a fisiológica e a comportamental [DARAMOLA, 2010].

Quando se fala de biometria fisiológica, como o próprio nome já induz, utilizam-se as características fisiológicas do indivíduo. Nesse sentido, são exemplos de características os padrões da íris [DAUGMAN, 2003] [FERREIRA, 1998], da impressão digital [JIN, 2002] [DAGHER, 2002], da face [CHAUDHARY, 2009] [ZHAO, 2008], da palma da mão [CHAUDHARY, 2009] [ZHANG, 2009], entre outros.

Em se tratando de reconhecer um indivíduo utilizando seu padrão de voz [CUI, 2009], o texto manuscrito [HOQUE, 2007] ou a assinatura manuscrita, essas se encaixam no contexto das biometrias comportamentais, as quais buscam identificar ou reconhecer um indivíduo por meio de um comportamento ou reação. A dificuldade dessa biometria é a grande possibilidade de variação das características com o tempo, podendo sofrer alterações de acordo com a idade ou por motivos físicos, psicológicos, emocionais entre outros [PLAMONDON, 1990].

Na necessidade de autenticar documentos, cartórios, bancos e demais empresas, utilizam, na sua grande maioria, a assinatura manuscrita grafada no documento, a fim de validá-lo. Devido a sua boa aceitação pelo público, e pela capacidade de armazenar inúmeras características de um determinado indivíduo, tem-se buscado automatizar este processo de reconhecimento e verificação das assinaturas, tendo em vista que esta biometria já está disseminada, possui respaldo legal e está sendo utilizada em massa, porém não de forma automatizada.

Em um de seus trabalhos, Justino [JUSTINO, 2001] cita a importância da assinatura no âmbito jurídico, pois essa é capaz de comprovar legalmente acordos firmados envolvendo documentos.

Na grafoscopia, peritos são capacitados para identificar indivíduos através de textos e assinaturas impressas em documentos questionados¹, os quais não são necessariamente falsificados, mas que necessitaram de uma análise grafotécnica para verificar sua autenticidade. Atualmente toda a análise efetuada pelos peritos é feita de forma manual, sem nenhum sistema ou mecanismo automatizado que possa auxiliar neste processo. [QUEIROZ, 2005]

Segundo Amaral e Mendes [AMARAL, 2000] [MENDES, 2003], a grafoscopia é ligada diretamente à documentoscopia², que, por sua vez, é ligada à criminalística, fazendo com que o estudo da grafia seja relevante em diversas áreas.

Além da importância do estudo da grafia estar presente nos mais diversos segmentos, com o tempo, e sobretudo, com o aumento das transações bancárias, o número de fraudes também têm aumentado. Este desafio impulsionou o desenvolvimento de estudos envolvendo reconhecimento de padrões já na década de 1960, quando foram feitas as primeiras pesquisas sobre reconhecimento e verificação de assinaturas manuscritas [SOUZA, 2009].

1.1 Motivação

A crescente utilização da assinatura como mecanismo para autenticar documentos ou firmar transações, e a necessidade de amadurecimento dos estudos no processo de verificação e reconhecimento automatizado de assinaturas, foram os pontos importantes no contexto deste projeto.

¹ Documentos que possivelmente foram falsificados, adulterados ou confeccionados por outro autor; documentos que possuem autenticidade questionada.

² É o estudo e a análise de documentos em geral, com o objetivo de verificar a sua autenticidade e/ou integridade, ou a autoria do punho escritor e/ou o instrumento gráfico produtor [MENDES, 2003].

A pouca disponibilidade de bases públicas de assinaturas também foi outro fator levado em consideração para a realização desta pesquisa, a qual se empenhou em criar uma base de dados independente, porém não disponível publicamente.

Os estudos na área de verificação de assinaturas *off-line* ainda não atingiram taxas muito relevantes em comparação com outras biometrias estudadas. Iniciativas como o ICDAR (*International Conference on Document Analysis and Recognition*) incentivam e alavancam melhorias nos trabalhos pertinentes a esta seara. Neste sentido, a base de dados disponibilizada no ICDAR 2011 também foi utilizada para efeito comparativo com outras pesquisas na área.

1.2 Objetivo

Este projeto objetiva verificar o desempenho da métrica Coeficiente de Correlação de Pearson para discriminar assinaturas manuscritas *off-line*.

Como objetivos específicos, podem-se citar os seguintes pontos:

- Criar uma base de dados de assinaturas manuscritas *off-line*;
- Efetuar um estudo comparativo sobre a forma de utilização das características extraídas utilizando o coeficiente de correlação, no momento da verificação;
- Analisar a utilização de uma RNA para classificar os coeficientes de correlação extraídos;
- Avaliar a utilização de uma abordagem com pesos associados aos limiares obtidos pela métrica utilizada;
- Avaliar estatisticamente os resultados.
- Avaliar o comportamento do melhor experimento com a base de dados disponibilizada no ICDAR 2011.

1.3 Organização da dissertação

No capítulo 2, serão abordados, com mais detalhes, assuntos pertinentes à verificação de assinaturas manuscritas, trazendo as diferenças entre assinaturas *on-line* e *off-line*, bem como a diferença entre verificação e reconhecimento de assinaturas. Também serão abordados assuntos como as medidas de desempenho utilizadas e trabalhos relacionados.

No terceiro capítulo, serão abordados os materiais e os métodos utilizados neste projeto, como: o processo de aquisição e preparação dos dados; a realização do pré-processamento das imagens; a segmentação dos dados; técnicas de extração de Características Periféricas e Diferenciais Periféricos; o Coeficiente de Correlação, mostrando como este algoritmo trabalha na comparação entre as imagens; a definição dos limiares com base nas correlações efetuadas; a configuração da rede neural artificial utilizada no experimento; e como funciona a curva ROC (*Receiver Operating Characteristics*) na comparação entre os experimentos realizados.

Em seguida, no quarto capítulo, serão abordados os 6 (seis) experimentos realizados, finalizando com um comparativo entre os experimentos.

Por fim, no quinto e último capítulo serão feitas as considerações finais do projeto, com o apontamento das contribuições desta pesquisa, os pontos fortes, fracos e algumas propostas de trabalhos futuros.

2. Verificação de Assinaturas Manuscritas

Apesar da assinatura ser uma biometria disseminada em diversas segmentos, existem alguns fatores que podem interferir na sua utilização: a falta de mecanismos de verificação automatizados e a possibilidade de variação entre as assinaturas são alguns dos exemplos relevantes.

No processo de verificação, existem, basicamente, duas formas distintas de variação: a intrapessoal, que consiste na variação entre as assinaturas de um mesmo autor, e a interpessoal, que corresponde a variação obtida entre dois autores tentando reproduzir uma mesma assinatura [NÁPOLES, 2011].

Na Figura 1 se pode observar, em termos gráficos, a diferença entre estas abordagens. Foram sobrepostos 6 exemplares de assinaturas genuínas e 6 exemplares de falsificações, demonstrando, respectivamente, as diferenças intrapessoal e interpessoal.

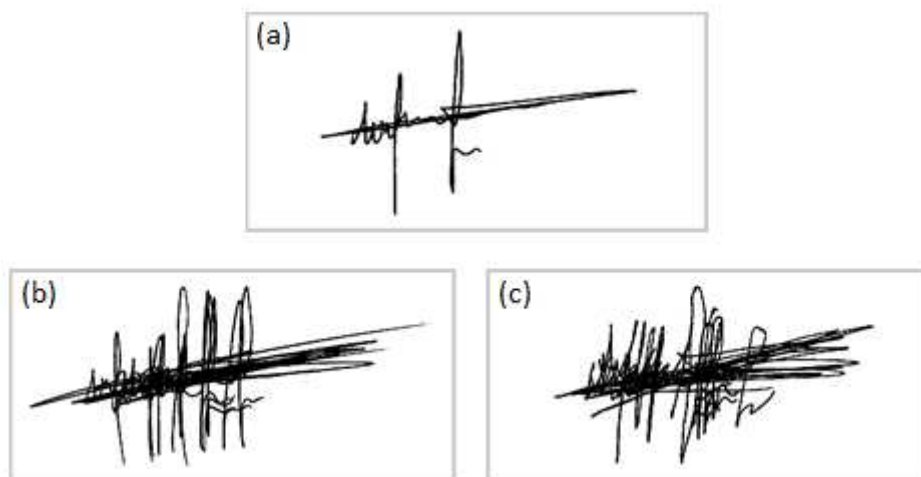


Figura 1 - Diferença entre variação intrapessoal e interpessoal: (a) assinatura genuína; (b) variação intrapessoal; (c) variação interpessoal.

Segundo Amaral e Mendes [AMARAL, 2000] [MENDES, 2003], as modificações que podem ocorrer na escrita, no tocante à sua forma, podem ser causadas por três espécies de fatores, que podem ser: involuntárias, voluntárias e patológicas.

Na Figura 2 pode-se visualizar de forma mais clara quais seriam as formas de modificação. Pode-se dizer que as modificações involuntárias e patológicas são consideradas variações intrapessoais, ao passo que as modificações voluntárias são consideradas interpessoais.

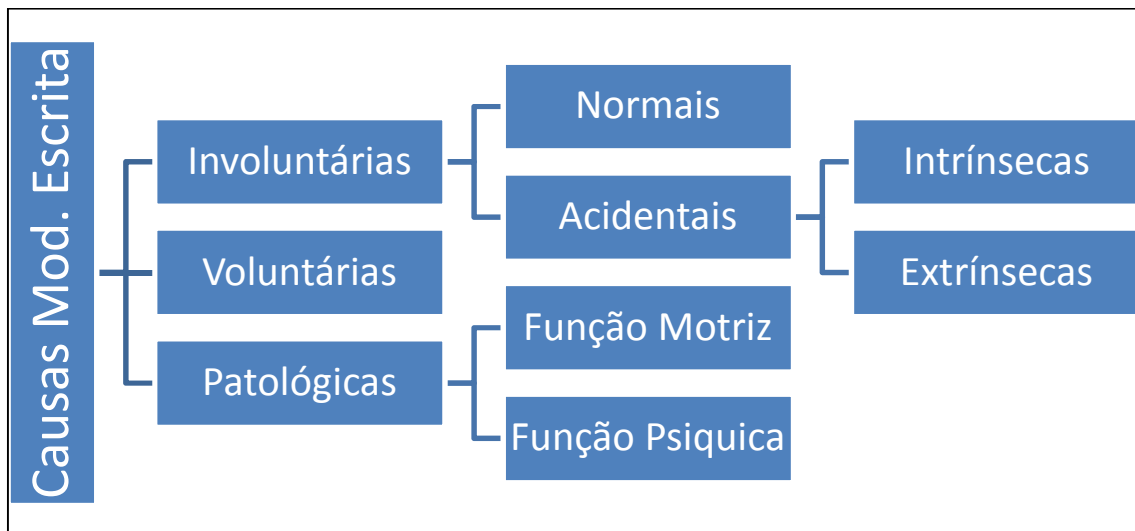


Figura 2 - Causas modificadoras da escrita. Adaptado de [MENDES, 2003].

Com base na Figura 2, pode-se concluir que [AMARAL, 2000] [MENDES, 2003]:

- As formas Normais estão relacionadas à própria evolução do gesto gráfico;
- As formas Acidentais Intrínsecas, por sua vez, dizem respeito a euforia, depressão, pavor, falta de atenção, ira, estado de embriaguez etc.;
- Já as formas Acidentais Extrínsecas estão relacionadas ao calor, frio, estado do instrumento de escrita, posição incômoda ao escrever, iluminação inadequada etc.;
- As modificações Voluntárias são as falsificações, as tentativas de reproduzir uma assinatura ou escrita de outra pessoa;
- Finalmente, as modificações causadas por fatores Patológicas são aquelas resultantes de moléstias, que dependendo da intensidade, podem até impossibilitar uma pessoa de escrever.

Independente das variações ou modificações, o processo padrão utilizado para efetuar a verificação de assinaturas, conforme pode ser visualizado na Figura 3, é realizado como segue:

- Inicialmente uma base de dados é coletada para treinar um algoritmo ou ser utilizada como referência durante o processo;
- A assinatura questionada é então capturada;
- Segue-se com o Pré-processamento: etapa na qual se buscam tratar ruídos e/ou executar algoritmos de processamento de imagens. Esta etapa objetiva oferecer melhores resultados de acordo com os métodos utilizados na extração de características e classificação;
- Passa-se à Extração de características: etapa na qual procede-se à extração dos dados discriminantes necessários ao processo de classificação;
- Por fim, a Verificação, etapa na qual a assinatura questionada pode ser rejeitada ou aceita como verdadeira.

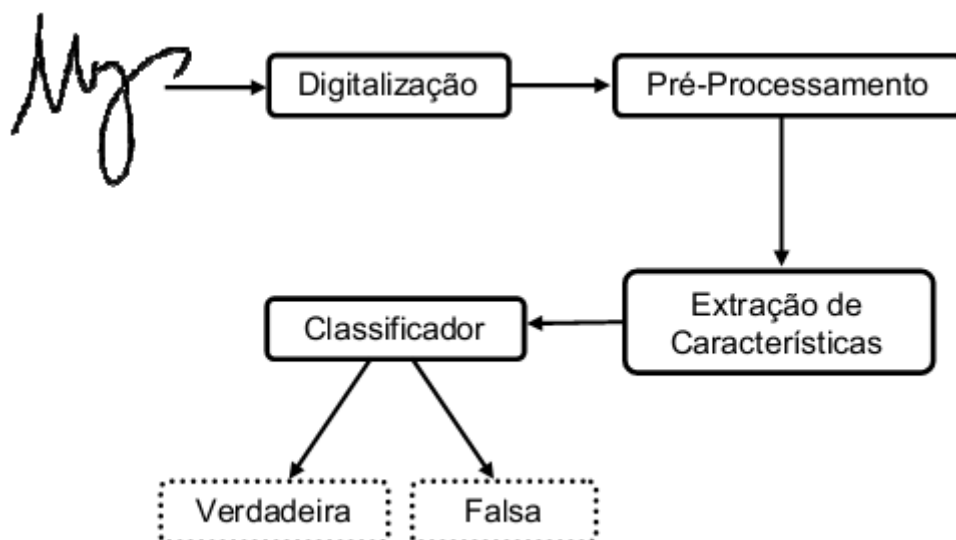


Figura 3 - Fluxo padrão utilizado no processo de verificação de assinaturas *off-line* [SOUZA, 2009].

Em seguida, serão abordados os tipos de falsificações; as diferenças entre assinaturas *on-line* e *off-line*; as diferenças entre verificação e reconhecimento de assinaturas e quais as medidas de desempenho utilizadas para efetuar a comparação entre os experimentos. Para finalizar este capítulo, serão expostas algumas pesquisas realizadas na área.

2.1 Tipos de Falsificações

Quando se fala das possibilidades de variação da assinatura, entram em cena os diversos tipos de falsificações, bem como as diferenças entre cada um desses tipos. Percebe-se que algumas das espécies de fraudes não foram tratadas a contento nos trabalhos existentes na área de verificação e reconhecimento, muitas vezes em virtude da falta de mecanismos para capturar suas características peculiares - as quais são utilizadas pelos peritos em grafoscopia por exemplo.

Segundo Justino [JUSTINO, 2001], a identificação de uma falsificação é vista, no âmbito do reconhecimento de padrões, como um problema entre duas classes, sendo uma delas a aceitação e a outra a rejeição. O autor cita ainda que a possibilidade de sua identificação depende das condições de teste e do meio.

As falsificações podem ser classificadas em três tipos [GONÇALVES, 2008]:

- Falsificações Aleatórias: são os exemplares reproduzidos pelo falsificador sem o conhecimento da grafia, nem do nome do autor da assinatura genuína. Geralmente esse tipo não possui nenhuma semelhança com a amostra original;
- Falsificação Simples: São os exemplares reproduzidos pelo falsificador com o prévio conhecimento do nome do autor da assinatura genuína, porém sem a ciência da grafia correta. Em alguns casos, esse tipo de falsificação pode assemelhar-se à assinatura original;

- Falsificação Servil, Habilidade ou Simulada: neste tipo, o falsificador possui uma cópia da assinatura genuína, a qual é utilizada como referência no momento da reprodução;

Pode-se ainda deparar com as seguintes possibilidades de falsificações, não comumente abordadas nas pesquisas de verificação e reconhecimento – conforme supramencionado - em virtude da falta de mecanismos adequados à captura de suas características pertinentes [MENDES, 2003] [AMARAL, 2000]:

- Falsificação Exercitada: Esse tipo de falsificação, em alguns casos, torna-se a mais complexa de se identificar. O falsificador, de posse de um exemplar da assinatura genuína, realiza um treinamento, praticando a cópia várias vezes, e só então efetua a reprodução definitiva, a qual será utilizada na comparação. Geralmente a reprodução definitiva é realizada sem o auxílio visual do modelo utilizado para treinamento;
- Falsificação de Memória: É um procedimento mais abreviado, no qual o falsificador utiliza um exemplar da assinatura genuína apenas para memorizar as principais características. No momento de reproduzir a falsificação, o modelo de referência não é utilizado. Diferentemente da modalidade exercitada, a falsificação de memória não envolve o treinamento exaustivo da cópia pelo falsificador antes de seu lançamento definitivo.
- Falsificação Decalque: Esse tipo de falsificação, como o próprio nome já induz, é uma cópia da assinatura original. Esse processo de cópia é realizado pelo método de transferência do grafismo mediante a pressão sobre ele. Para isso, geralmente, são utilizados canetas, lápis, etc. e, em alguns casos, finalizando com um acabamento.

Dentre essas modalidades, a falsificação exercitada e a falsificação decalque são as de utilização mais improvável, pois precisam de técnicas mais profundas, como a da Luz Rasante, a qual é utilizada pelos peritos para detectar a pressão em assinaturas *off-line* [MENDES, 2003].

2.2 Assinaturas *On-line* e *Off-line*

No momento de se reproduzir uma assinatura, essa pode ser escrita diretamente no papel, com o auxílio de uma caneta, lápis etc., ou pode ser capturada por um *tablet* ou mesa digitalizadora.

A diferença básica de assinaturas *on-line* para *off-line* está na forma de aquisição. Nesse sentido, as assinaturas *on-line* são capturadas diretamente por mesas digitalizadoras ou *tablets*. Através deste processo, características diferenciadas e relevantes são adquiridas, porém, a preparação de uma base de dados, e a própria forma de se trabalhar com essa abordagem, demandam hardware apropriado – o que torna este método mais complexo e custoso [PLAMONDON, 2000].

As assinaturas *off-line*, por sua vez, são capturadas através de um *scanner* ou câmera fotográfica a partir de um documento previamente assinado, não dependendo de um hardware específico para efetuar sua reprodução inicial. Sendo assim, a utilização dessa abordagem se torna muito mais simples para as empresas, pois o investimento em hardware é bem menor, e o ambiente utilizado para o processo pode ser menos complexo [PLAMONDON, 2000].

Na Figura 4 são expostos esses dois tipos de verificação, bem como os desdobramentos da modalidade *off-line*, destacando as formas que serão abordadas neste projeto.

Nesse sentido, pode-se destacar as seguintes abordagens:

- Globais: Utilizam características gerais da imagem;
- Locais: A imagem original é segmentada e a análise é efetuada em cada segmento, possibilitando a percepção de detalhes de cada sub-imagem;

- Contextual: Busca correlacionar as letras do nome do autor com o modelo da assinatura. Técnica mais utilizada por sistemas de reconhecimento de caracteres;
- Não Contextual: Utiliza os aspectos geométricos e estáticos do traçado da assinatura;
- Estática (local ou global): Utiliza como características os aspectos pertinentes à forma da imagem da assinatura;
- Pseudo-dinâmica (local ou global): Utiliza aspectos relacionados à dinâmica da escrita, a exemplo da inclinação [JUSTINO, 2001] [MÉLO, 2011].

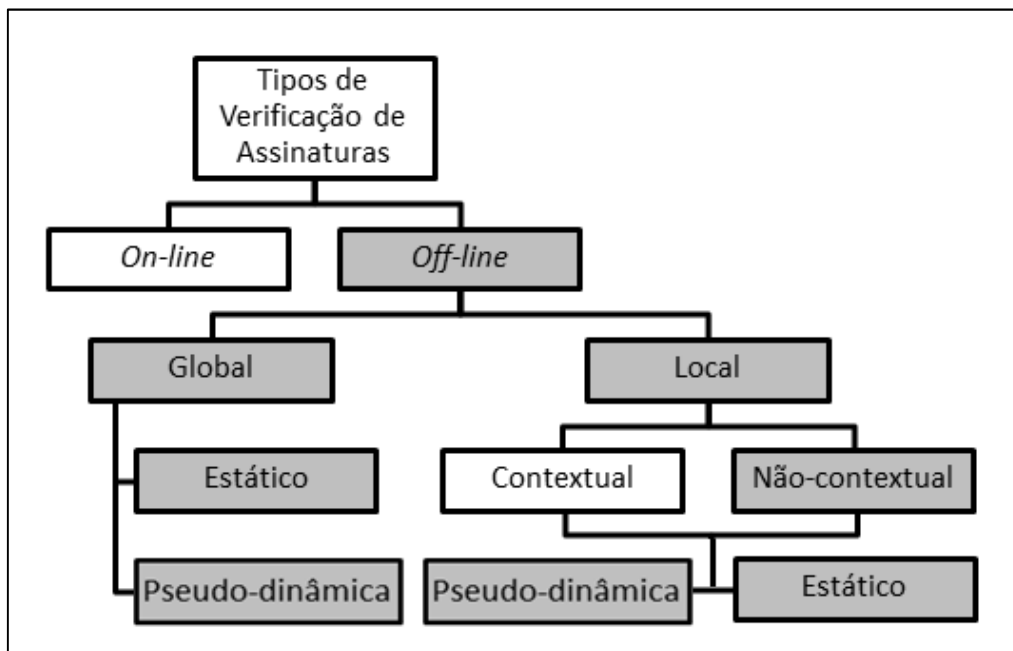


Figura 4 - Diagrama hierárquico das abordagens utilizadas no processo de verificação de assinaturas [Adaptado de MÉLO, 2011].

2.3 Verificação versus Reconhecimento

No âmbito do reconhecimento de padrões, depara-se com a necessidade de se identificar um padrão em um determinado contexto. Como exemplo, pode-se citar o reconhecimento de voz, no qual se busca identificar o que está sendo dito em vez de quem está falando.

Outro exemplo é o reconhecimento de manuscritos, que consiste na capacidade de identificar o que está sendo escrito, convertendo-se tudo em texto, e não identificando quem está escrevendo [CARVALHO, 1999].

O OCR (*Optical Character Recognition*) é um exemplo prático do que seria o reconhecimento, o qual identifica letras e/ou números impressos em imagens, convertendo tudo em texto.

Quando se trata de verificação, por outro lado, depara-se com a necessidade de informar se um determinado pressuposto é verdadeiro ou falso [SANTOS, 2004].

Como exemplo, pode-se citar a verificação de voz, que busca identificar quem está falando – em vez do que está sendo dito – identificado o autor, busca-se validar sua identidade frente uma amostra de referência. A verificação da assinatura segue a mesma ideia, buscando identificar se o que está sendo assinado é um exemplar genuíno ou uma falsificação.

Nesse sentido, pode-se dizer que o processo de reconhecimento é um relacionamento 1:N e verificação é 1:1.

2.4 Medidas de Desempenho

Tendo vistas as principais diferenças entre verificação e reconhecimento, neste ponto serão abordadas as medidas de desempenho adotadas por diversos trabalhos nesta área.

Para a análise dos experimentos serão utilizadas as Taxas de Falsa Aceitação (FAR) e de Falsa Rejeição (FRR). A falsa aceitação ocorre quando uma assinatura falsa é aceita como verdadeira, gerando um resultado também chamado de falso positivo. A falsa rejeição, por outro lado, ocorre quando uma assinatura genuína é rejeitada, sendo tratada como uma falsificação, resultando no que também é conhecido como falso negativo [COETZER, 2005].

$$FRR = \frac{\text{Quantidade de assinaturas genuínas rejeitadas}}{\text{Quantidade de assinaturas genuínas submetidas}} \quad (1)$$

$$FAR = \frac{\text{Quantidade de assinaturas falsas aceitas}}{\text{Quantidade de assinaturas falsas submetidas}} \quad (2)$$

Outras taxas também utilizadas, como no trabalho de Souza [SOUZA, 2009], são a Taxa de Verdadeira Aceitação (TAR), quando uma assinatura genuína é reconhecida com sucesso, também conhecida como verdadeiro positivo, e a Taxa de Verdadeira Rejeição (TRR), quando uma falsificação é corretamente rejeitada, o chamado verdadeiro negativo.

$$TRR = \frac{\text{Quantidade de assinaturas falsas rejeitadas}}{\text{Quantidade de assinaturas falsas submetidas}} \quad (3)$$

$$TAR = \frac{\text{Quantidade de assinaturas genuínas aceitas}}{\text{Quantidade de assinaturas genuínas submetidas}} \quad (4)$$

Alguns trabalhos, como o de Coetzer [COETZER, 2005], utilizaram a Taxa de Erro Médio (AER), a qual é calculada através da média entre o FAR e o FRR.

$$AER = \frac{FRR + FAR}{2} \quad (5)$$

Nos trabalhos do ICDAR também é muito utilizada a *Accuracy* (Taxa de Acerto), que é calculada pela equação (6).

$$Accuracy = \frac{VP + VN}{V + N} \quad (6)$$

Onde:

- VP = Quantidade de assinaturas genuínas aceitas;
- VN = Quantidade de assinaturas falsas rejeitadas;
- V = Quantidade de assinaturas genuínas submetidas;
- N = Quantidade de assinaturas falsas submetidas.

Nesse sentido, a necessidade do trabalho é que ditará qual a taxa que se deseja aperfeiçoar. Neste projeto será priorizada a redução da taxa FAR, pois o custo de se aceitar uma falsificação é maior do que o de se descartar uma assinatura genuína.

2.5 Trabalhos Relacionados

Nas pesquisas que utilizam a abordagem *on-line*, os autores Jain e Griess [JAIN, 2002] utilizaram pontos críticos na escrita da assinatura, como velocidade e ângulo de curvatura, reportando uma taxa FRR (*False Rejection Ratio*) de 2,8% e FAR (*False Acceptance Ratio*) de 1,6%. Foram utilizados limiares comuns e limiares específicos por indivíduo. Os melhores resultados foram alcançados nos limiares gerados por indivíduo, em detrimento dos limiares comuns, que são calculados considerando as assinaturas de todos os indivíduos. Em seu trabalho, eles utilizaram duas bases de dados. A primeira foi composta de um total de 520 assinaturas, as quais foram geradas por 52 indivíduos, cada um dispondo de 10 exemplares; e de 60 falsificações habilidosas, as quais foram geradas por 20 indivíduos. A segunda base de dados utilizou um total de 1.232 assinaturas genuínas, as quais foram produzidas por 102 indivíduos, que contribuíram com pouco mais de 10 assinaturas cada um; e de 60 falsificações, produzidas da mesma forma utilizada na base de dados 1.

Keit e Palanjppan [KEIT, 2001] utilizaram um método baseado na pressão da caneta, capturada através de um hardware específico, para fins de identificação. Neste trabalho, eles obtiveram uma taxa FRR de 2,13% e FAR de 3,40%, no melhor resultado. Foi utilizada uma base de dados de assinaturas contendo 1.000 exemplares, as quais foram utilizadas para treinamento e teste. As assinaturas foram produzidas por 20 pessoas.

Hasna [HASNA, 2006], por sua vez, propôs uma abordagem utilizando redes neurais artificiais para o reconhecimento de assinaturas dinâmicas. Em sua metodologia, foi utilizado o algoritmo do Gradiente Conjugado, chegando a uma taxa FRR de 1,6%, a taxa FAR não foi reportada. A base de dados foi

composta por 77 assinaturas genuínas, as quais foram utilizadas para treinamento. O teste foi realizado utilizando 5 participantes para produzir as falsificações habilidosas.

No que tange aos trabalhos que utilizam a abordagem *off-line*, foco desta dissertação, pode-se citar algumas pesquisas, como a de Justino [JUSTINO, 2002], que utilizou o HMM (*Hidden Model Markov*) como classificador. As características utilizadas foram: densidade dos pixels, distribuição dos pixels (*Extended-Shadow-Code*) e inclinação axial. Nesse sentido, foram alcançadas as seguintes taxas: FRR de 2,83% e FAR de 1,44% para falsificações aleatórias, FAR de 2,50% para falsificações simples e FAR de 22,67% para falsificações habilidosas. Para compor a base de dados de referência, foram coletadas 5.200 imagens de assinaturas. Desse montante, existem 4.000 assinaturas genuínas oriundas de 100 autores diferentes (40 amostras de assinaturas para cada autor) e 1.200 falsificações, geradas a partir dos 60 primeiros modelos de assinaturas genuínas. Foram produzidas 10 falsificações simples e 10 falsificações habilidosas para cada modelo.

Já Mélo [MÉLO, 2011] utilizou morfismo como classificador no processo de reconhecimento. Dentre os cenários utilizados em seu projeto, o que obteve melhor resultado, utilizando falsificações habilidosas, retornou uma taxa FRR de 11,67% e FAR de 20% para falsificações simples e 30% para falsificações habilidosas. Como base de dados, foi utilizada a base disponibilizada no ICDAR 2011 *Signature Verification Competition*, composta por 240 assinaturas genuínas, que foram geradas por 10 autores (cada autor cedendo 24 assinaturas), e 120 falsificações habilidosas.

Gonçalves [GONÇALVES, 2008] utilizou agrupamento de classificadores para a verificação de assinaturas. Para isso, implementou um algoritmo genético para trabalhar na fusão desses classificadores. As características utilizadas neste projeto foram: distribuição de *pixels*, curvatura, densidade de *pixels* e inclinação *axial*. As taxas encontradas, no melhor caso, foram: FRR de 7,32% e FAR de 4,32% para falsificações habilidosas e FAR de 3,32% para falsificações aleatórias. Sua base de dados foi a mesma utilizada por [JUSTINO, 2002] com 5.200 imagens de assinaturas no total.

Souza [SOUZA, 2009], por sua vez, utilizou uma abordagem baseada na combinação de distâncias e classificadores de uma classe. Como características, utilizou o *Shadow Code*, Características Periféricas e Diferenciais Periféricos e Elementos Estruturais. Os classificadores empregados no melhor resultado foram o SVDD (*Support Vector Data Description*) e o LPDD (*Linear Programming Dissimilarity-data Description*). Para analisar o resultado obtido, foi fixado o FAR em 5% e 10%, para assim avaliar o TAR (*True Acceptance Ratio*) resultante. Com o FAR fixo em 10%, obteve-se o TAR de 91,87%, quando utilizadas falsificações aleatórias; e de 59,18%, quando utilizadas falsificações habilidosas. Partiu-se de duas bases de dados: a base de dados 1 foi a mesma utilizada por Gomes [GOMES, 1995], contendo 1.732 assinaturas, sendo 1.057 genuínas, 343 falsificações habilidosas e 332 falsificações aleatórias; e a base de dados 2 foi a mesma disponibilizada no ICDAR 2009, sendo composta por 60 assinaturas genuínas, as quais foram produzidas por 12 voluntários, e 1.838 falsificações habilidosas, as quais foram produzidas por 31 voluntários.

3. Materiais e Métodos

Neste capítulo, serão expostas as ferramentas, os métodos, as funções e as metodologias empregadas na realização desta dissertação.

Primeiramente será visto o conceito de pré-processamento dos dados. Em seguida, será apresentado o processo de extração de características, bem como os algoritmos utilizados. No tópico seguinte, será abordado o Coeficiente de Correlação, além dos limiares que serão utilizados no decorrer dos experimentos. Para finalizar, será apresentado o modelo de redes neurais artificiais utilizado para classificar os dados, e como se dá o emprego da curva ROC na comparação dos classificadores.

3.1 Aquisição da Base de Assinaturas

Para este projeto foram utilizadas duas bases de dados, a primeira, devido à pouca disponibilidade de bases públicas e utilizadas como referência nos trabalhos da literatura, foi gerada de forma independente. A segunda base de dados, a qual foi utilizada apenas no sexto experimento, foi a mesma disponibilizada no ICDAR 2011.

3.1.1 Base de Dados I

Para produzir as assinaturas da primeira base de dados, foi utilizado um grid de 5x2, totalizando 10 espaços, em papel A4. Todos os exemplares foram gerados em condições satisfatórias de posicionamento e iluminação, ou seja, os indivíduos estavam sentados em uma mesa, com luz ambiente, sem luz solar ou direcional.

Foram utilizados 94 indivíduos para produzir as assinaturas genuínas, totalizando 940 exemplares, e 6 indivíduos para produzir as falsificações habilidosas, totalizando 470 exemplares. No total, foram geradas 1.410 assinaturas.

		Rayssa A. Nascimento		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		
		Lúcia Pereira da Silva		

Tabela 1 - Exemplo de uma assinatura de cada autor que participou do processo de captura.

Na Tabela 1 pode-se observar um exemplar da assinatura de cada um dos 94 autores que participaram do processo de captura.

Na Figura 5 pode-se visualizar um exemplo de documento de assinaturas, o qual contém os dez exemplares de um determinado autor.




Figura 5 - Exemplo de um documento de assinaturas utilizando um Grid 5x2.

Na Figura 6, pode-se visualizar um exemplo de documento de assinaturas falsas do mesmo autor utilizado no exemplo da Figura 5.




Figura 6 - Exemplo de documento de assinaturas falsas.

Sua captura para o meio digital foi realizada através de um scanner Fujitsu fi-6130Z configurado com 300 dpi de resolução.

3.1.2 Base de Dados II

A segunda base de dados será a mesma disponibilizada pelo ICDAR 2011, a qual é composta por 240 assinaturas genuínas, que foram geradas por 10 autores (cada autor cedendo 24 assinaturas), e 120 falsificações habilidosas.

Essa mesma base de dados também foi utilizada em trabalhos como o de Mélo [MÉLO, 2011].

Na Tabela 2 pode-se observar um exemplo da assinatura de cada um dos 10 autores que participaram do processo geração da base de assinaturas, a qual foi disponibilizada no ICDAR 2011.


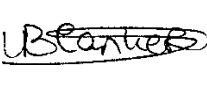

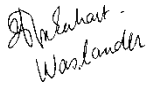
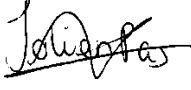


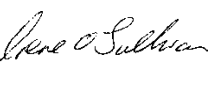
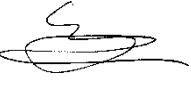
	L.C. Almeida			
				

Tabela 2 - Exemplo de uma assinatura de cada autor que compôs a base disponibilizada no ICDAR 2011.

3.2 Pré-Processamento

Visando uma melhor adequação da imagem para trabalhar na extração das características, e buscando minimizar os ruídos que porventura possam ser gerados no momento da digitalização, foi efetuada a binarização das imagens e, em seguida, foi realizada a segmentação, separando cada documento de assinaturas em 10 exemplares distintos.

O documento de assinaturas consiste numa folha de papel A4 contendo os 10 exemplares de assinaturas separadas por um grid, como pode ser visto na Figura 5. Cada assinatura foi centralizada em uma região com tamanhos pré-definidos empiricamente com 600x1.280 pixels, conforme a Figura 7.

O processo de centralização consiste em identificar o centro de massa da assinatura e posicioná-la no centro de uma região de 600x1.280 pixels, cujo espaço restante é preenchido com pixels brancos. Nesse sentido, o tamanho da assinatura é preservado do processo de captura. Não foi explorada nesta dissertação a normalização do tamanho da assinatura, a qual pode influenciar nos resultados em ambientes reais. Isto foi definido, pois esta variação quase não existia na base utilizada. Consideramos que aplicada esta normalização os resultados obtidos devem se manter.

Houve necessidade de uniformizar os tamanhos das imagens das assinaturas, em virtude do algoritmo de extração do Coeficiente de Correlação

trabalhar apenas com imagens de mesmas dimensões [BANDYOPADHYAY, 2008].




Figura 7 - Exemplo de assinatura pré-processada.

Essa proporção de 600x1.280 pixels foi utilizada porque, após digitalizar a folha A4 com 300 dpi de resolução, cada local de assinatura ficou com aproximadamente esta dimensão.

3.3 Extração das Características

Em virtude da peculiaridade do Coeficiente de Correlação relativa às dimensões das imagens, a classificação utilizou segmentos da imagem também de mesmo tamanho. Partindo desse pressuposto, as características utilizadas foram:

1. Assinatura original: Como pode ser visto na Figura 7;
2. Regiões das assinaturas, também chamadas de Características Periféricas e Diferenciais Periféricos (CPDP) [FANG, 2002];
3. Segmentação da imagem original, e das regiões das imagens geradas após a execução do algoritmo CPDP.

Nos tópicos abaixo, serão abordados com mais detalhes os pontos 2 e 3 citadas anteriormente.

3.3.1 Características Periféricas e Diferenciais Periféricos

Com o objetivo de produzir uma quantidade maior de imagens para serem utilizadas como características, foi empregado o algoritmo Características Periféricas e Diferenciais Periféricos (CPDP) para gerar regiões distintas a partir da assinatura original [FANG, 2002].

Como pode ser visto na Tabela 3, foram produzidas 8 imagens a partir da imagem original, utilizando, como mencionado, os conceitos do algoritmo CPDP - porém com o uso de apenas uma faixa horizontal e uma faixa vertical [SOUZA, 2009] [FANG, 2002].

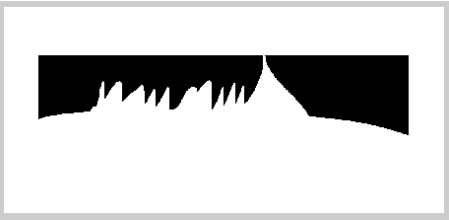
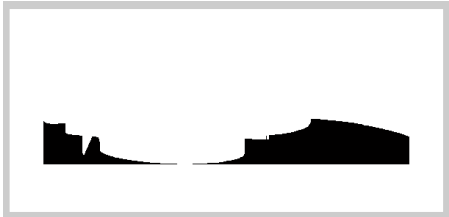
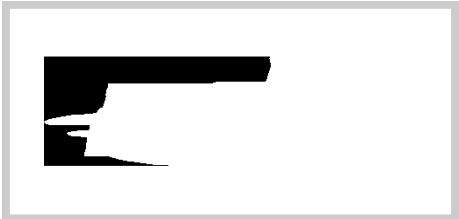
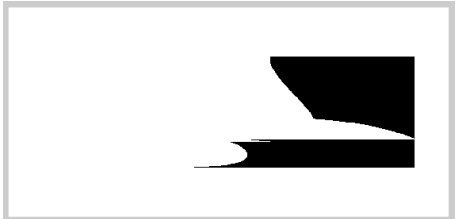
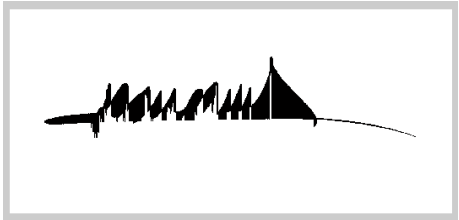
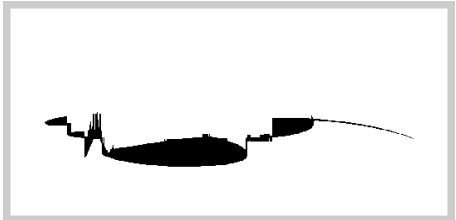
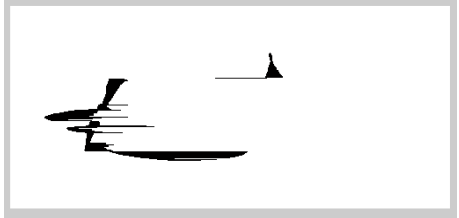
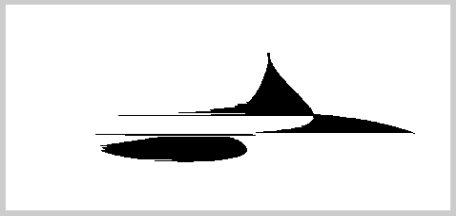
 Região Superior	 Região Inferior
 Região Esquerda	 Região Direita
 Região Superior Interno	 Região Inferior Interno
 Região Esquerda Interno	 Região Direita Interno

Tabela 3 - Exemplo de CPDP baseado na Figura 7.

A partir disso, as seguintes regiões foram geradas:

- a. Região Superior: Corresponde à área localizada acima da assinatura;
- b. Região Inferior: Corresponde à área localizada abaixo da assinatura;
- c. Região Esquerda: Corresponde à área localizada a esquerda da assinatura;
- d. Região Direita: Corresponde à área localizada a direita da assinatura;
- e. Região Superior Interno: Corresponde à área localizada na parte superior da assinatura percorrendo-a de cima para baixo;
- f. Região Inferior Interno: Corresponde à área localizada na parte inferior da assinatura percorrendo-a de baixo para cima;
- g. Região Esquerda Interno: Corresponde à área localizada no lado esquerdo da assinatura percorrendo-a da esquerda para a direita;
- h. Região Direita Interno: Corresponde à área localizada no lado direito da assinatura percorrendo-a da direita para a esquerda;

3.3.2 Segmentação

A partir da imagem original, a segmentação foi realizada utilizando um grid de 10x20, gerando 200 regiões de tamanho 60x64 pixels, obtidos empiricamente. Na Figura 8, pode-se observar um exemplo de segmentação realizada em uma imagem original e outra em uma imagem das regiões extraídas durante a execução do algoritmo CPDP.




Figura 8 - Segmentação da Imagem original e da região superior por intermédio de um grid de 10x20.

Durante esse processo, foram geradas um total de 1.800 regiões, utilizando todas as projeções supracitadas, incluindo todas as imagens geradas com a execução do CPDP.

3.4 Coeficiente de Correlação de Pearson

Como visto, para tratar as características extraídas, foi utilizado o Coeficiente de Correlação de Pearson, o qual retorna um coeficiente entre cada bloco de imagem de mesmo tamanho. [BANDYOPADHYAY, 2008] [IRANMANESH, 2013].

Essa sistemática baseada em coeficiente de correlação também foi utilizada em trabalhos de reconhecimento de assinaturas como o de Bandyopadhyay [BANDYOPADHYAY, 2008], que, todavia, não reportou erros do tipo FRR ou FAR, ou mesmo AER. Em sua pesquisa foram apresentados os valores do coeficiente retornado no momento do treinamento e do teste.

Outro projeto que também abordou essa metodologia na verificação de assinaturas foi o de Iranmanesh [IRANMANESH, 2013], o qual utilizou uma abordagem com assinaturas *on-line*, utilizando uma RNA como classificador. Em seu trabalho, a base de dados utilizada foi a do SIGMA, que contém 8.000 assinaturas fornecidas por 200 usuários (cada usuário forneceu 20 assinaturas genuínas, 10 falsificações habilidosas e 10 falsificações aleatórias). O autor alcançou uma taxa FRR de 13,81% e FAR global de 21,35%, no melhor caso.

A fórmula para extrair o Coeficiente de Correlação de Pearson é dada pela equação (7):

$$r = \frac{\sum_m \sum_n (A_{mn} - \bar{A})(B_{mn} - \bar{B})}{\sqrt{\left(\sum_m \sum_n (A_{mn} - \bar{A})^2 \right) \left(\sum_m \sum_n (B_{mn} - \bar{B})^2 \right)}} \quad (7)$$

Onde **A** e **B** são os blocos de imagens a ser comparados e convertidos em uma matriz cujo conteúdo das células é o valor do pixel correspondente. A variável \bar{A} corresponde a média dos elementos de **A**, e \bar{B} corresponde a média dos elementos de **B**.

No processo de comparação entre duas imagens utilizando o algoritmo em questão, os dados são tratados da seguinte forma: quanto mais próximo de 1 for o coeficiente (r), mais parecidas as imagens são; se o coeficiente for 1, isso implica dizer que as imagens são idênticas; quanto mais próximo de 0 for o coeficiente, mais divergentes são as imagens; e se o coeficiente apresentar 0, quer dizer que as imagens comparadas são o inverso da outra, ou seja, possuem seus pixels completamente diferentes.

Após encontrar o coeficiente de todas as sub-imagens que representam as duas assinaturas analisadas, encontra-se a média dos coeficientes, o qual é utilizado ou na geração do limiar, ou para alimentar os parâmetros de entrada de um classificador.

3.4.1 Definição de Limiares

Para identificar se uma assinatura será aceita ou rejeitada, foram traçados três limiares. O primeiro utiliza a média; o segundo, a mediana, e o terceiro corresponde a junção da média com a mediana dos coeficientes da assinatura em questão.

A média dos coeficientes da assinatura genuína de um determinado autor (s) é dada pela equação (8).

$$\overline{GR}_s = \left(\sum_{i=1}^N (GR_{si}) \right) / N \quad (8)$$

Onde N é o total de correlações entre assinaturas genuínas de um determinado autor, e GR_s é o coeficiente entre duas assinaturas genuínas desse mesmo autor.

A média dos coeficientes entre assinaturas genuínas e falsificações de um determinado autor (s) é dada pela equação (9).

$$\overline{FR}_s = \left(\sum_{i=1}^M (FR_{si}) \right) / M \quad (9)$$

Onde M é a quantidade de relacionamentos entre assinaturas genuínas e falsificações de um determinado autor, e FR_s é o coeficiente extraído entre os relacionamentos desse autor em questão.

Da mesma forma, calcula-se a mediana dos coeficientes FR_s e GR_s , que é dada pelas equações (10) e (11).

$$GRm_s = \text{mediana}(GR_s) \quad (10)$$

$$FRm_s = \text{mediana}(FR_s) \quad (11)$$

Para a realização dos experimentos, conforme mencionado, foram utilizados três tipos de limiares. O primeiro foi o limiar “Média dos Coeficientes”, que é dado pela equação (12).

$$L1_s = \frac{(\overline{GR}_s + \overline{FR}_s)}{2} \quad (12)$$

O segundo limiar calculado é o “Mediana dos Coeficientes”, que é dado pela equação (13).

$$L2_s = \frac{(GRm_s + FRm_s)}{2} \quad (13)$$

O terceiro e último limiar é calculado utilizando a junção dos dois anteriores, buscando uma redução de falsos positivos. O limiar “Média Mediana” é dado pela equação (14).

$$L3_s = \begin{cases} L1_s, & L1_s \geq L2_s \\ L2_s, & L1_s < L2_s \end{cases} \quad (14)$$

Os experimentos realizados utilizaram os limiares L1, L2 e L3, um classificador e pesos associados aos limiares.

3.5 Redes Neurais Artificiais

Com o desenvolvimento e o amadurecimento dos estudos com RNA, vários trabalhos foram desenvolvidos no campo de verificação e reconhecimento de assinaturas manuscritas, utilizando RNA como classificador.

Como exemplo, pode-se citar o projeto NeuralSignX, o qual utiliza um sistema neural para efetuar a autenticação de assinaturas manuscritas on-line [HEINEN, 2005]. Outro projeto que também utilizou RNA foi o de Abikoye, Mabayoje e Ajibade, o qual desenvolveu um sistema de verificação e reconhecimento de assinaturas manuscritas off-line, no qual o processo iniciava-se com a digitalização das assinaturas [ABIKOYE, 2011].

Nesta pesquisa, a rede utilizada foi do tipo MLP (*Multi-Layer Perceptron*), treinada pelo algoritmo *backpropagation*, a qual possibilita a representação de uma rica variedade de superfícies de decisão não lineares.

De maneira simplificada, o que alimentou a RNA foi o relacionamento entre assinaturas genuínas - o qual caracteriza uma classe -, e o relacionamento entre uma assinatura genuína e uma falsificação, fosse ela habilidosa ou aleatória, caracterizando a segunda classe.

A saída da RNA foi representada por dois neurônios:

- (0 1) – para representar a classe de relacionamento entre assinaturas genuínas;

- (1 0) – para representar a classe de relacionamento entre uma assinatura genuína e uma falsificação.

Na literatura, existem algumas funções utilizadas pelo neurônio artificial para efetuar sua ativação, dentre as quais pode-se citar três tipos: Função Linear, Função Limiar e Função Sigmoidal. Para o experimento, será utilizada a Função Sigmoidal do tipo Logística, uma das mais importantes da literatura [BRAGA, 2007], e que gerou melhores resultados.

A função Sigmoidal Logística, como pode ser observada na Figura 9, varia entre zero e um, e possui um parâmetro (t) que determina a suavidade da curva [BRAGA, 2007].




Figura 9 - Função de ativação Sigmoidal Logística.

Em seguida será detalhado o processo utilizado para ajustar a base de assinaturas, gerando os conjuntos de treinamento, validação e teste.

Partindo do pressuposto de que um dado consiste em um autor com todos os exemplares de sua assinatura, foram separados 50% dos dados para representar o conjunto de treinamento – ou seja, todas as assinaturas de metade dos autores. A outra metade foi separada da seguinte forma: 25% para o conjunto de validação e 25% para o conjunto de teste.

Nesse sentido, os autores utilizados no conjunto de teste e validação foram excluídos do conjunto de treinamento. Em outras palavras, o conjunto de

treinamento não é composto por 50% das assinaturas de cada indivíduo, mas sim de 50% dos indivíduos que cederam assinaturas.

Para efetuar o treinamento, foram utilizadas as seguintes configurações:

- Quantidade de neurônios na camada oculta: 5, 15 e 25, respectivamente, sem alteração nos pesos para não divergir nos resultados.
- Taxas de aprendizado utilizadas: 0.00015, 0.0002 e 0.00025.
- Quantidade de iterações realizadas: 1000, 1500 e 2000.

Na tentativa de evitar *overfitting*, foi fixado em 5 (cinco) o valor máximo de erros consecutivos no momento do aprendizado da rede. Todos os valores foram definidos empiricamente.

3.6 Curva ROC

Utilizada em larga escala pelas comunidades médicas para avaliar diagnósticos, em especial diagnósticos de imagens, o gráfico ROC (*Receiver Operating Characteristics*) foi originado na teoria de decisão estatística nos anos 1950, e vem sendo utilizado até os dias de hoje [SOUZA, 2009] [FAWCETT, 2004].

O gráfico ROC é uma técnica para visualização, organização e seleção de classificadores baseado em seus desempenhos. Atualmente a área de aprendizado de máquina, em especial a análise de classificadores, está utilizando cada vez mais essa técnica [FAWCETT, 2004].

Para um ambiente envolvendo duas classes $\{p, n\}$, no qual se encaixa este projeto, uma será a Positiva, envolvendo os relacionamentos de assinaturas genuínas, e a outra a Negativa, a qual corresponde aos relacionamentos de uma assinatura genuína com uma falsificação. Cada uma dessas classes, por sua vez, pode ser classificada de duas formas distintas $\{P, N\}$, Positiva e Negativa.

Com base neste ambiente, e como mostra a Figura 10, as seguintes situações podem ser encontradas:

- VP (Verdadeiro Positivo): Ocorre quando um exemplar da classe Positivo {p} é classificado corretamente;
- FN (Falso Negativo): Ocorre quando um exemplar da classe Positivo {p} é classificado incorretamente como Negativo;
- FP (Falso Positivo): Ocorre quando um exemplar da classe Negativo {n} é classificado incorretamente como Positivo;
- VN (Verdadeiro Negativo): Ocorre quando um exemplar da classe Negativo {n} é classificado corretamente.

	p	n
P	Verdadeiro Positivo	Falso Positivo
N	Falso Negativo	Verdadeiro Negativo

Figura 10 - Matriz confusão [SOUZA, 2009].

Para a geração do gráfico ROC, é necessário calcular as seguintes taxas [FAWCETT, 2004]:

$$\text{Taxa de Verdadeiros Positivos} = \frac{VP}{P} \quad (15)$$

$$\text{Taxa de Falso Positivo} = \frac{FP}{N} \quad (16)$$

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (17)$$

$$\text{Taxa de acerto} = \frac{VP + VN}{P + N} \quad (18)$$

Nesse sentido, para um melhor entendimento das equações (15), (16), (17) e (18) considera-se:

- VP: Quantidade de Verdadeiros Positivos;
- FP: Quantidade de Falsos Positivos;
- VN: Quantidade de Verdadeiros Negativos;
- P: Quantidade de exemplos da classe Positivo;
- N: Quantidade de exemplos da classe Negativo.

Um gráfico ROC simplesmente é a relação entre a Taxa de Verdadeiros Positivos (TAR) e a Taxa de Falsos Positivos (FAR).

Os classificadores discretos, conforme pode ser visualizado na Figura 11, são representados apenas por um ponto no gráfico. O ponto **D** é um exemplo de classificador ideal, sem gerar erros de classificação. Por outro lado, no caso do ponto **E**, pode-se dizer há a geração de resultados negativos, e invertendo-se a saída, esse mesmo classificador passará a gerar resultados positivos.




Figura 11 - Gráfico ROC exibindo 5 classificadores discretos [adaptado de FAWCETT, 2004].

Para a geração da Curva ROC, vários pontos necessitarão ser gerados, para assim permitir a análise do comportamento do classificador. Nesse

sentido, e baseado no Algoritmo 1 [FAWCETT, 2004] [SOUZA, 2009], é necessário obter um *ranking* ou *score* de cada exemplo do conjunto de teste para a produção da curva. Esse *score* utilizado pode ser a probabilidade de aquele dado exemplo ser positivo dentre os demais.

Algoritmo 1: Geração dos pontos da Curva ROC

Entrada: L , representa o conjunto de exemplos de teste; $f(i)$, seria a probabilidade do exemplo i ser classificado como Positivo; P e N , que seria a quantidade de exemplos positivos e negativos, respectivamente.

Saída: R , seria uma lista de pontos para a geração da Curva ROC.

Requisitos: $P > 0$ and $N > 0$

```

1:  $L_{sorted} \leftarrow L$    sorted é decrementado baseado no score da função  $f$ 
2:  $FP \leftarrow VP \leftarrow 0$ 
3:  $R \leftarrow ()$ 
4:  $f_{prev} \leftarrow -\infty$ 
5:  $i \leftarrow 1$ 
6: Enquanto  $i \leq |L_{sorted}|$  faça
7:   se  $f(i) \neq f_{prev}$  então
8:      $push\left(\frac{FP}{N}, \frac{VP}{P}\right)$  onto  $R$ 
9:      $f_{prev} \leftarrow f(i)$ 
10:  fim
11:  se  $L_{sorted}[i]$  é um exemplo Positivo então
12:     $VP \leftarrow VP + 1$ 
13:  senão
14:     $FP \leftarrow FP + 1$ 
15:  fim
16:   $i \leftarrow i + 1$ 
17: fim
18:  $push\left(\frac{FP}{N}, \frac{VP}{P}\right)$  onto  $R$ 

```

Para o Algoritmo 1, considera-se VP como sendo a ocorrência de uma classificação correta e FP como sendo uma classificação incorreta.

Na Figura 12 pode ser visualizado um exemplo da curva ROC para análise de dois classificadores, A e B. De acordo com o observado, o classificador A possui uma taxa de acerto, em quase toda a análise, maior que B.

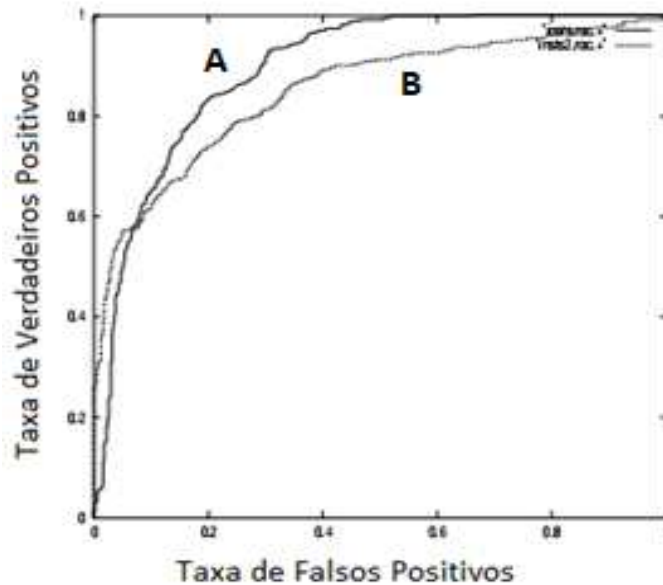


Figura 12 - Exemplo de Curva ROC para análise de dois classificadores discretos [adaptado de FAWCETT, 2004].

3.6.1 Área Abaixo da Curva ROC (AUC)

Devido à necessidade de obtenção de dados escalares para efetuar a análise entre classificadores, e baseado na Curva ROC, este projeto também fez uso da área abaixo da curva, também conhecida como AUC (*Area Under Curve*).

Como a Curva ROC é a representação do desempenho do classificador em um gráfico bidimensional, para uma análise mais precisa, é necessário reduzir o valor utilizado para um escalar na comparação.

A AUC concentra o valor de desempenho dos classificadores em um escalar entre 0.0 e 1.0, levando em consideração o que foi reproduzido pela Curva ROC. Sua geração é realizada através do Algoritmo 2 [FAWCETT, 2004] [SOUZA, 2009].

Algoritmo 2: Calculo da área abaixo da Curva ROC (AUC)

Entrada: L , representa o conjunto de exemplos de teste; $f(i)$, seria a probabilidade do exemplo i ser classificado como Positivo; P e N , que seria a quantidade de exemplos positivos e negativos, respectivamente.

Saída: A , área abaixo da Curva ROC.

Requisitos: $P > 0$ and $N > 0$

```
1:  $L_{sorted} \leftarrow L$    sorted é decrementado baseado no score da função  $f$ 
2:  $FP \leftarrow VP \leftarrow 0$ 
3:  $FP_{prev} \leftarrow VP_{prev} \leftarrow 0$ 
4:  $A \leftarrow 0$ 
5:  $f_{prev} \leftarrow -\infty$ 
6:  $i \leftarrow 1$ 
7: Enquanto  $i \leq |L_{sorted}|$  faça
8:   se  $f(i) \neq f_{prev}$  então
9:      $A \leftarrow A + \text{TRAPEZOID\_AREA}(FP, FP_{prev}, VP, VP_{prev})$ 
10:     $f_{prev} \leftarrow f(i)$ 
11:     $FP_{prev} \leftarrow FP$ 
12:     $VP_{prev} \leftarrow VP$ 
13:   fim
14:   se  $i$  é um exemplo Positivo então
15:      $VP \leftarrow VP + 1$ 
16:   senão
17:      $FP \leftarrow FP + 1$ 
18:   fim
19:    $i \leftarrow i + 1$ 
20: fim
21:  $A \leftarrow A + \text{TRAPEZOID\_AREA}(1, FP_{prev}, 1, VP_{prev})$ 
22:  $A \leftarrow \frac{A}{P * N}$ 
```

1: **Função** $\text{TRAPEZOID_AREA}(X1, X2, Y1, Y2)$

2: $Base \leftarrow |X1 - X2|$

3: $Height_{avg} \leftarrow \frac{Y1 + Y2}{2}$

4: **retorna** $Base * Height_{avg}$

Para o Algoritmo 2, considera-se VP como sendo a ocorrência de uma classificação correta e FP como sendo uma classificação incorreta.

Nesse sentido, na Figura 13 pode-se visualizar a comparação entre dois classificadores utilizando a AUC.

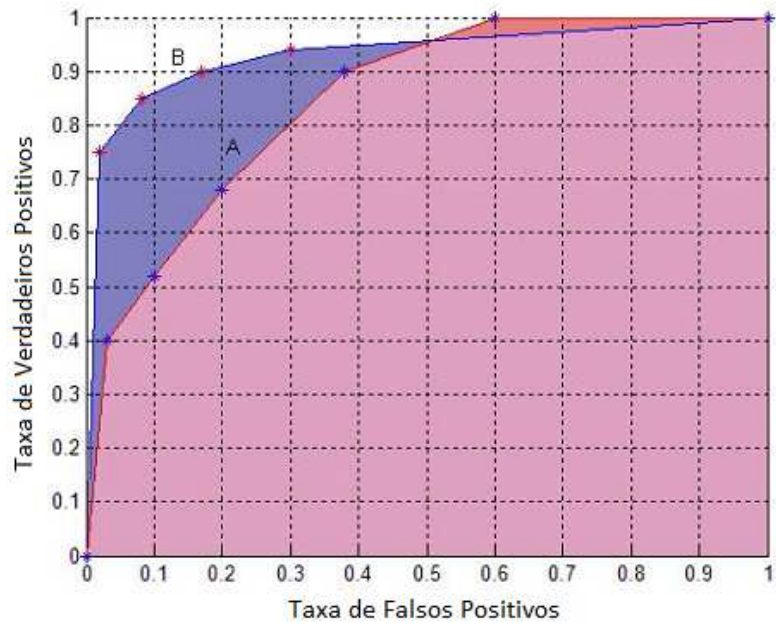


Figura 13 - AUC de dois classificadores A e B [adaptado de FAWCETT, 2004].

De acordo com o observado, o classificador B é melhor que A, porém em alguns pontos A possui um desempenho melhor que B.

4. Experimentos

Neste capítulo, será abordado todo o processo realizado para a concretização dos experimentos, desde a sua configuração até a análise dos resultados obtidos, terminando com uma análise comparativa.

Do primeiro experimento ao quinto foi utilizada apenas a base de dados I, a base de dados II foi utilizada no sexto experimento.

Levando em consideração que o cálculo do limiar aceitação/rejeição depende da qualidade das características, os experimentos 1, 2 e 3 foram focados apenas na utilização dos limiares L1, L2 e L3 para efetuar a categorização das assinaturas, variando-se apenas a quantidade de características utilizadas no processo, o que gerou, dessa forma, limiares diferenciados.

No quarto experimento, foi utilizada uma Rede Neural Artificial do tipo MLP como classificador para efeito comparativo com os demais experimentos.

No quinto experimento, baseando-se em trabalhos como o de Souza [SOUZA, 2009], foi associado um peso aos limiares, buscando-se reduzir as taxas de falsos positivos (FAR) em 5% e 10%, permitindo a análise, dessa forma, das taxas resultantes de verdadeiros positivos (TAR).

No sexto e último experimento, para efeito de comparação com outros trabalhos relacionados à área de verificação de assinaturas, será utilizada a base de dados disponibilizada no ICDAR 2011. Para este experimento será utilizada a mesma configuração do melhor caso dentre os anteriores.

4.1 Modelos Propostos

Para os experimentos 1, 2, 3 e 5, os quais se equiparam a uma busca local, foram separadas 70% das assinaturas genuínas de cada indivíduo para compor o conjunto de referência - que é utilizado para gerar o limiar de um indivíduo isolado. Nesse sentido, cada autor terá um limiar diferenciado.

Esse conjunto de referência também recebe 70% das falsificações habilidosas e 3 exemplares de assinaturas de outros autores para simular as falsificações aleatórias. Os 30% restantes, seja do conjunto de assinaturas genuínas, de falsas habilidosas ou de falsas aleatórias, são utilizados para compor o conjunto de teste. De forma geral, o processo é realizado da seguinte forma:

1. É efetuado o relacionamento entre as assinaturas genuínas, gerando-se, dessa forma, vetores de média e de mediana do coeficiente desses relacionamentos;
2. Em seguida, é efetuado o relacionamento entre assinaturas genuínas e falsificações, e gerada a média e a mediana dos coeficientes entre esses relacionamentos;
3. Com a média e a mediana dos coeficientes desses relacionamentos, são gerados os limiares para o autor em questão;
4. O teste é realizado analisando a média ou a mediana do coeficiente de correlação que é gerado através do relacionamento entre uma assinatura questionada e as assinaturas genuínas presentes no conjunto de referência. Se a média ou mediana do coeficiente estiver acima do limiar utilizado, a assinatura é aceita; caso contrário, será descartada.

Na Figura 14 pode-se visualizar melhor como seria o processo de treinamento e teste para os experimentos 1, 2 e 3, considerando que as assinaturas já passaram pelas etapas de pré-processamento e extração das características. Em relação às características utilizadas, depois de alguns experimentos, foram separadas três configurações distintas, uma para cada experimento, conforme será visto no decorrer do capítulo.

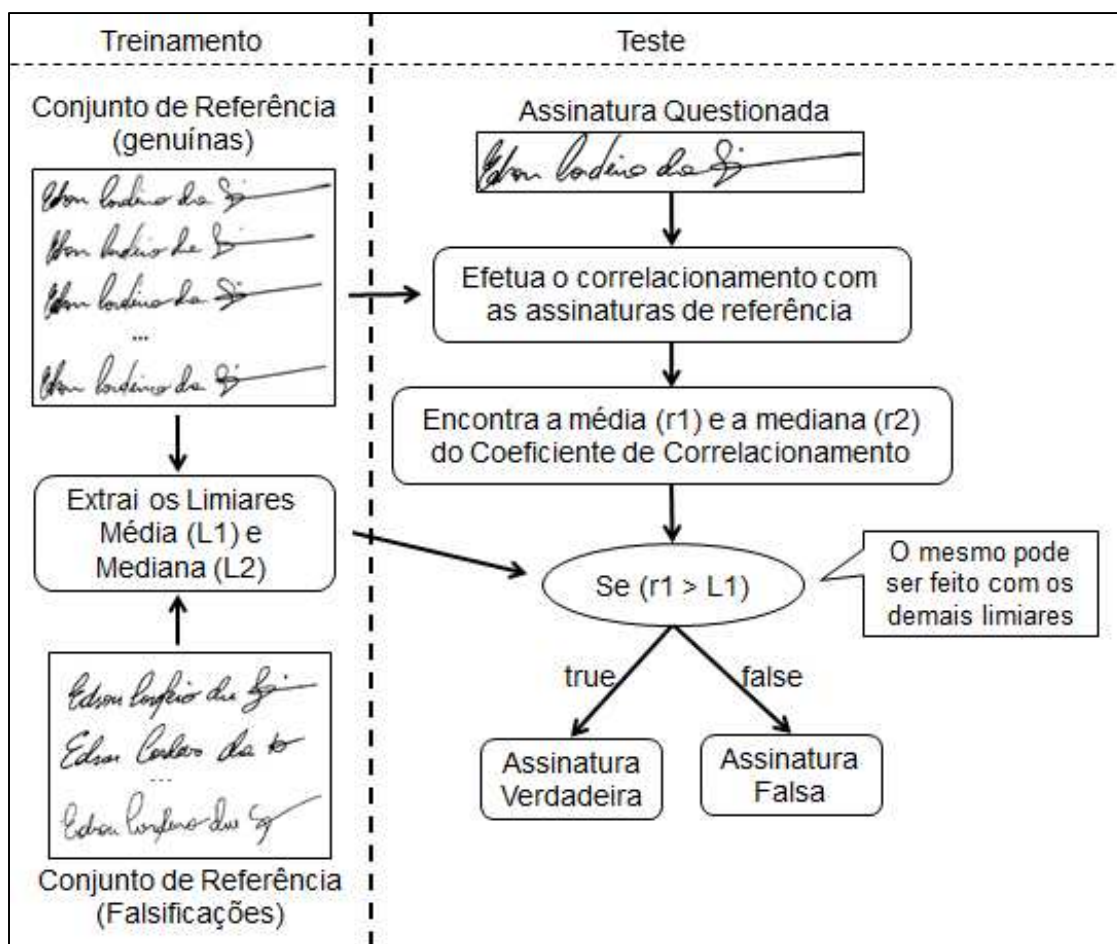


Figura 14 - Fluxo de execução utilizado nos experimentos 1, 2 e 3.

Ainda na Figura 14, o limiar L3 não está exposto pois seu cálculo é baseado na junção da média com a mediana, favorecendo a rejeição após calcular das duas formas. Por exemplo, se uma assinatura questionada for aceita utilizando o L1 e rejeitada utilizando o L2, o L3 priorizará a rejeição, ou seja, também rejeitará. Nesse sentido, o L3 só aceitará uma assinatura questionada se a análise utilizando o L1 e o L2 classificar como verdadeira.

4.1.1 Primeiro Experimento

Na realização deste experimento, foi utilizado a base de dados I, bem como os 3 limiares citados anteriormente (L1, L2 e L3), porém nem todas as características extraídas foram utilizadas. Segue abaixo as características utilizadas:

1. Assinatura original;
2. Regiões das assinaturas:
 - a. Região Superior;
 - b. Região Inferior;
 - c. Região Esquerda;
 - d. Região Direita;
 - e. Região Superior Interno;
 - f. Região Inferior Interno;
 - g. Região Esquerda Interno;
 - h. Região Direita Interno.
3. Segmentação da imagem original, utilizando um grid de 10x20, totalizando 200 regiões da imagem de tamanho 60x64 pixels.

Sendo assim, foram geradas 209 imagens, que foram utilizadas no processo de extração dos coeficientes por meio da Correlação de Pearson.

Após a execução dos testes, foram observados os seguintes resultados, conforme pode ser visualizado na Tabela 4.

	Média (L1)	Mediana (L2)	Junção (L3)
VP	90,43%	87,94%	86,52%
FP: Global	9,04%	9,93%	8,69%
FP: Habilidosas	17,38%	19,15%	16,67%
FP: Aleatórias	0,71%	0,71%	0,71%

Tabela 4 - Resultados do primeiro experimento.

Utilizando o limiar L3 (a junção da média e da mediana), o sistema prioriza a rejeição visando baixar a Taxa de Falso Positivo.

4.1.2 Segundo Experimento

Na realização deste experimento foi utilizada a base de dados I, como também os 3 limiares citados anteriormente (L1, L2 e L3), porém uma nova configuração das características foi utilizada. Segue abaixo as características utilizadas:

1. Assinatura original;
2. Regiões das assinaturas:
 - a. Região Superior;
 - b. Região Inferior;
 - c. Região Esquerda;
 - d. Região Direita;
 - e. Região Superior Interno;
 - f. Região Inferior Interno;
 - g. Região Esquerda Interno;
 - h. Região Direita Interno.
3. Segmentação da imagem original, utilizando um grid de 10x20, totalizando 200 regiões da imagem, cada segmento ficou com o tamanho de 60x64 pixels.
4. Segmentação das Regiões Superior, Inferior, Esquerda e Direita, utilizando um grid de 10x20, totalizando 800 regiões da imagem analisada, cada segmento ficou com o tamanho de 60x64 pixels.

Sendo assim, foram geradas 1009 imagens, destinadas à utilização no processo de extração dos coeficientes.

Após a execução dos testes, foram observados os seguintes resultados, conforme a Tabela 5.

	Média (L1)	Mediana (L2)	Junção (L3)
VP	89,72%	87,23%	86,17%
FP: Global	10,11%	10,82%	9,57%
FP: Habilidosas	19,50%	20,92%	18,44%
FP: Aleatórias	0,71%	0,71%	0,71%

Tabela 5 - Resultados do segundo experimento.

4.1.3 Terceiro Experimento

Seguindo a linha de raciocínio do primeiro e do segundo experimento, para este também foi utilizada a base de dados I, bem como os 3 limiares citados anteriormente (L1, L2 e L3). Uma nova configuração das características foi empregada. Segue abaixo as características utilizadas:

1. Assinatura original;
2. Regiões das assinaturas:
 - a. Região Superior;
 - b. Região Superior Interno;
 - c. Região Inferior;
 - d. Região Inferior Interno;
3. Segmentação da imagem original, utilizando um grid de 10x20, totalizando 200 regiões da imagem, cada segmento ficou com o tamanho de 60x64 pixels.

Sendo assim, foram geradas 205 imagens destinadas à utilização no processo de extração dos coeficientes.

Após a execução dos testes, foram observados os resultados expostos na Tabela 6.

	Média (L1)	Mediana (L2)	Junção (L3)
VP	88,30%	85,46%	84,75%
FP: Global	10,28%	10,64%	9,57%
FP: Habilidade	19,50%	20,21%	18,09%
FP: Aleatórias	1,06%	1,06%	1,06%

Tabela 6 - Resultados do terceiro experimento.

4.1.4 Quarto Experimento – RNA como Classificador

Para este experimento, foi utilizado um classificador que se adapta às variáveis de forma dinâmica, de modo a quantificar o grau de importância de cada variável para o problema. A base de dados I também foi utilizada nesta etapa.

Para efeito comparativo com os demais experimentos, foi utilizado como classificador uma rede neural artificial, cujo funcionamento utiliza os pesos sinápticos para ponderar o grau de importância de cada variável de entrada.

Sendo assim, diferentemente do que foi realizado nos experimentos 1, 2 e 3, será utilizada uma RNA para testar os coeficientes de correlações entre as assinaturas, sem a utilização dos limiares previamente configurados.

Para efetuar o relacionamento entre duas assinaturas, e dessa forma gerar o coeficiente que foi utilizado para alimentar os parâmetros de entrada da RNA, foram utilizadas todas as características extraídas, que são as seguintes:

1. Assinatura original;
2. Regiões das assinaturas:
 - a. Região Superior;
 - b. Região Inferior;
 - c. Região Esquerda;
 - d. Região Direita;
 - e. Região Superior Interno;

- f. Região Inferior Interno;
 - g. Região Esquerda Interno;
 - h. Região Direita Interno.
3. Segmentação da imagem original, utilizando um grid de 10x20, totalizando 200 regiões da imagem, cada segmento ficou com o tamanho de 60x64 pixels.
 4. Segmentação das Regiões supracitadas, utilizando um grid de 10x20, totalizando 1600 segmentos da imagem analisada, cada segmento ficou com o tamanho de 60x64 pixels.

Nesse sentido, foram geradas 1.809 imagens a serem utilizadas no processo de extração dos coeficientes por meio da Correlação de Pearson, que, posteriormente, foram utilizados para alimentar a rede neural.

Na Figura 15, pode-se observar o fluxo realizado neste experimento, considerando que as assinaturas já passaram pelas etapas de pré-processamento e extração das características.

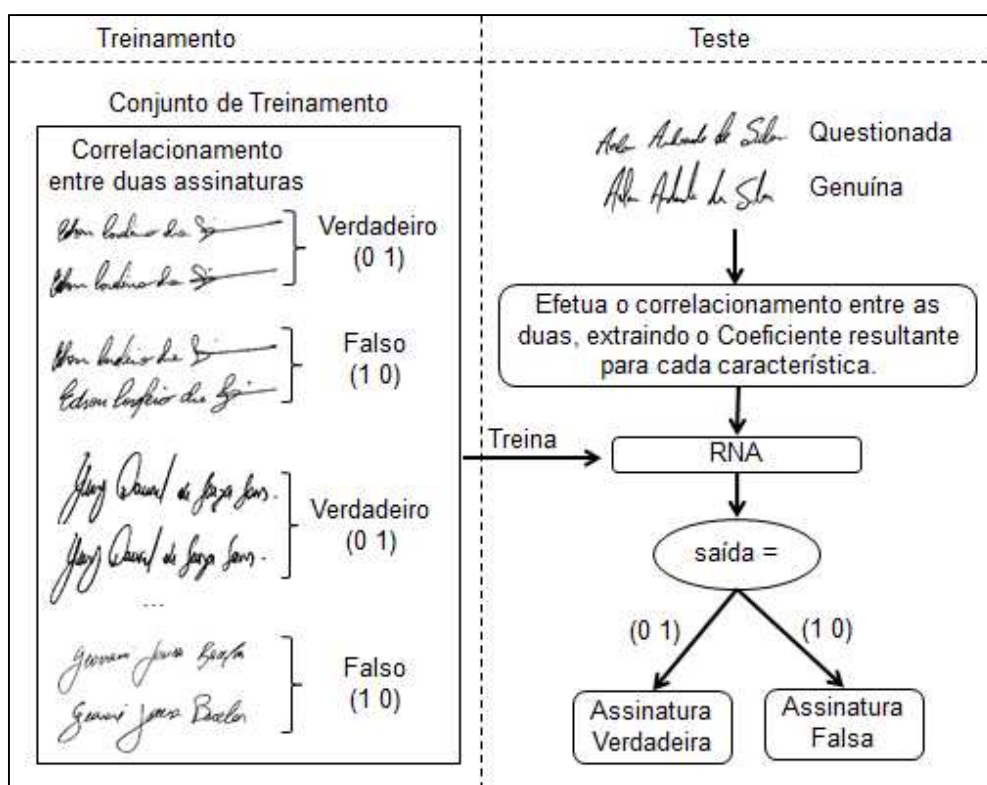


Figura 15 – Fluxo de execução utilizado no quarto experimento.

Na Tabela 7 poderão ser analisadas as 27 simulações efetuadas. Dentre elas, a de número 19 reportou o melhor resultado, com um erro de 14,37% de falsos positivos, e com uma taxa de classificação de verdadeiros positivos em 80,22%. Vale ressaltar que o melhor resultado foi identificado levando em consideração a menor taxa de falsos positivos.

Neurônios	TX Aprendizado	Iterações	Nr	% FAR	% TAR
5	0,00015	1000	1	15,37%	83,92%
		1500	2	15,22%	84,86%
		2000	3	15,13%	83,92%
	0,0002	1000	4	15,41%	84,58%
		1500	5	15,08%	84,01%
		2000	6	14,94%	83,73%
	0,00025	1000	7	15,04%	84,48%
		1500	8	14,94%	83,73%
		2000	9	14,94%	83,73%
15	0,00015	1000	10	14,75%	82,88%
		1500	11	14,56%	83,07%
		2000	12	14,80%	83,26%
	0,0002	1000	13	14,56%	82,97%
		1500	14	14,80%	83,16%
		2000	15	14,66%	83,54%
	0,00025	1000	16	14,70%	83,07%
		1500	17	14,66%	83,35%
		2000	18	14,61%	83,63%
25	0,00015	1000	19	14,37%	80,22%
		1500	20	14,61%	80,42%
		2000	21	14,66%	80,98%
	0,0002	1000	22	14,42%	80,32%
		1500	23	14,66%	80,98%
		2000	24	14,70%	80,89%
	0,00025	1000	25	14,75%	80,61%
		1500	26	14,75%	81,08%
		2000	27	14,52%	80,98%

Tabela 7 - Resultado das 27 simulações com conservação dos pesos.

Após identificação da melhor configuração da RNA baseado nas simulações presentes na Tabela 7, os resultados obtidos neste experimento podem ser visualizados na Tabela 8.

	RNA
VP	88,22%
FP: Global	14,37%
FP: Habilidosas	26,42%
FP: Aleatórias	2,32%

Tabela 8 - Resultado do quarto experimento após ajuste das configurações da RNA.

4.1.5 Quinto Experimento – Pesos Associados aos Limiares

No processo de verificação de assinaturas, o custo de reconhecer uma assinatura falsa como verdadeira é muito maior do que o de descartar uma assinatura genuína. Nesse intuito, foram utilizados pesos associados aos limiares L1, L2 e L3 utilizados nos experimentos 1, 2 e 3, a fim de diminuir a taxa de falsos positivos. A base de dados I também foi utilizada nesta etapa.

Os pesos foram ajustados para reduzir essa taxa para 5% e 10%, e assim verificar o percentual de verdadeiros positivos que se consegue com essa configuração. Essa sistemática também pode ser observada em trabalhos como o de Souza [SOUZA, 2009].

Dentre os experimentos realizados neste projeto, o primeiro experimento foi selecionado para servir como base para esta etapa, pois foi o que alcançou o melhor resultado dentre os demais. Seus limiares, então, foram reconfigurados, como pode ser visto nas equações (19) e (20):

$$L1_s = \frac{(\overline{GR}_s + \overline{FR}_s)}{2} * \omega \quad (19)$$

$$L2_s = \frac{(GRm_s + FRm_s)}{2} * \omega \quad (20)$$

Onde ω , é o peso associado ao limiar.

Após a execução dos testes, os resultados obtidos regulando os pesos para 5% e 10% de falsos positivos podem ser observados na Tabela 9.

No caso do L3, o falso positivo ficou ainda menor do que o pré-estabelecido, pois seu limiar é calculado com base no L1 e L2.

		Média (L1)	Mediana (L2)	Junção (L3)
FP: Habilidosas em 10%	VP	78,72%	73,76%	71,99%
	FP: Global	5,32%	5,50%	4,61%
	FP: Habilidosas	10,28%	10,28%	8,87%
	FP: Aleatórias	0,35%	0,71%	0,35%
FP: Habilidosas em 5%	VP	70,92%	60,64%	59,22%
	FP: Global	2,84%	2,84%	1,95%
	FP: Habilidosas	5,32%	5,32%	3,55%
	FP: Aleatórias	0,35%	0,35%	0,35%

Tabela 9 - Resultado do quinto experimento.

Como pode ser observado, utilizando os pesos associados aos limiares, foi possível reduzir ainda mais a taxa de falso positivo (FP). No melhor caso, fixando o FP em 10%, alcançou-se uma taxa de 78,72% de verdadeiros positivos, e fixando o FP em 5%, alcançou-se uma taxa de 70,92% de verdadeiros positivos.

4.1.6 Sexto Experimento – Utilizando a base do ICDAR2011

No intuito de analisar os classificadores utilizados nesta pesquisa com outras bases já utilizadas em trabalhos relacionados. Nesta etapa será utilizada a base de dados II, a qual foi disponibilizada no ICDAR 2011.

Como o primeiro experimento alcançou os melhores resultados dentre os demais, esse foi selecionado para ser refeito utilizando essa nova base de dados. A preparação da base também segue o mesmo princípio utilizado no primeiro experimento.

Após a execução do primeiro experimento utilizando a base de dados II, os seguintes resultados podem ser visualizados, conforme mostra a Tabela 10.

	Média (L1)	Mediana (L2)	Junção (L3)
VP	88,89%	87,30%	87,30%
FP: Global	9,72%	9,72%	9,72%
FP: Habilidade	19,44%	19,44%	19,44%
FP: Aleatórias	0,00%	0,00%	0,00%

Tabela 10 - Resultado do sexto experimento.

4.2 Comparação entre os Experimentos

Para a comparação entre os experimentos, foi utilizada a análise da curva ROC e a área abaixo da curva (AUC), sendo esta última mais precisa, devido à proximidade dos gráficos em alguns experimentos.

As taxas de falsos positivos citadas no decorrer dessa análise serão do tipo global, a qual é composta pela média entre as habilidades e as aleatórias. O tipo Global exibido no gráfico da curva ROC também segue o mesmo modelo de cálculo.

De acordo com o apresentado nos experimentos 1, 2, 3, 4 e 5, o melhor caso – o qual retornou maior AUC Global – foi o reportado pelo limiar L1 do primeiro experimento. As taxas resultantes neste caso foram de 9,04% de falsos positivos e 90,43% de verdadeiros positivos.

Com a utilização de uma RNA como classificador, o melhor caso apresentou uma taxa de falsos positivos de 14,37%, ficando com 80,22% de verdadeiros positivos.

Depois de alguns testes realizados, foi identificado que a quantidade de falsos positivos pode melhorar ainda mais com a utilização de pesos associados aos limiares. Nesse sentido, após ajustar os pesos para aceitar 5% de Falsos Positivos, obteve-se uma taxa de 70,92% de verdadeiros positivos, utilizando, para isso, falsificações habilidosas.

Na Figura 16 pode-se visualizar a Curva ROC para os classificadores utilizados no primeiro experimento. Nesse caso a classificação realizada foi baseada na utilização dos limiares L1, L2 e L3 com o emprego de uma

configuração diferenciada das características - a qual influenciou na geração dos limiares.

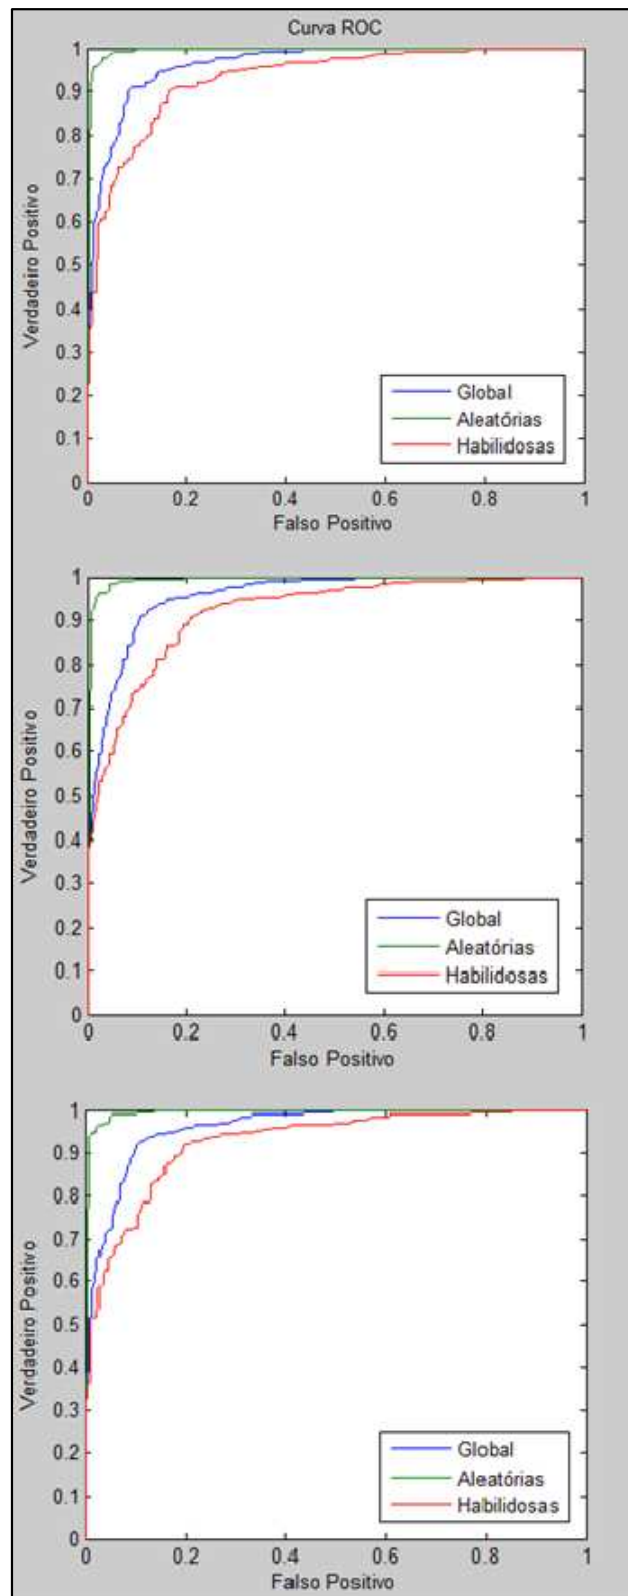


Figura 16 - Para o primeiro experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.

A Curva ROC dos classificadores utilizados no segundo experimento pode ser visualizada na Figura 17, cuja configuração dos limiares segue o mesmo padrão do primeiro experimento. Alterou-se apenas a configuração das características, o que gerou limiares diferenciados.




Figura 17 - Para o segundo experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.

Na Figura 18 é apresentada a Curva ROC dos classificadores utilizados no terceiro experimento, o qual também segue o padrão de configuração realizado no primeiro e no segundo. Efetuou-se uma nova configuração das características, o que gerou novos limiares.




Figura 18 - Para o terceiro experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente.

A Curva ROC do classificador utilizado no quarto experimento, que foi implementado utilizando uma RNA, pode ser visualizada na Figura 19.

Na Figura 20 pode-se observar a Curva ROC dos classificadores utilizados no quinto experimento, o qual empregou como base o melhor caso reportado entre os experimentos 1, 2 e 3. Como o melhor resultado foi reportado pelo L1 do primeiro experimento, esse foi utilizado como base para a inclusão do peso no limiar.

Os valores da AUC de todos os classificadores podem ser visualizados na Tabela 11, a qual destaca o L1 do primeiro experimento, que obteve uma AUC Global de 0,963.

Para finalizar a análise dos experimentos utilizando a base de dados I, na Figura 21 pode-se visualizar a curva ROC dos melhores resultados dos experimentos 1, 2, 3 e 4. No qual o primeiro experimento teve a melhor AUC Global.




Figura 19 - Curva ROC para o classificador utilizado no quarto experimento, no qual foi implementado uma RNA.

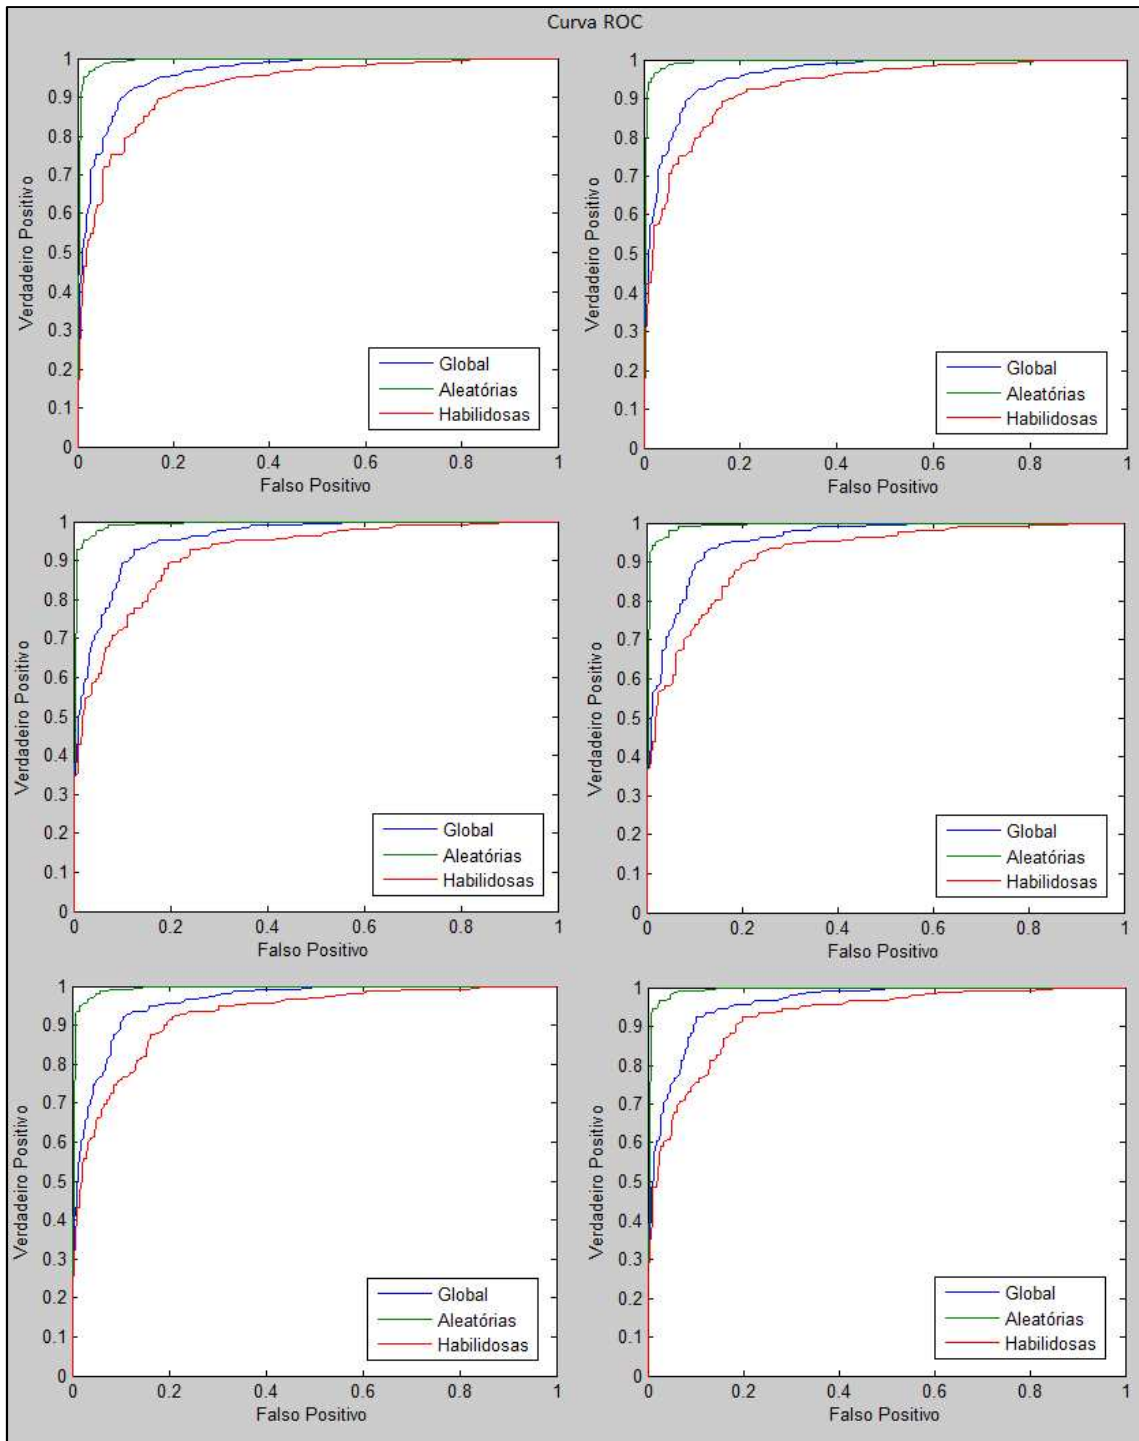


Figura 20 - Para o quinto experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente, sendo na coluna da esquerda com ajuste do limiar para 5% de falsos positivos e na coluna da direita com ajuste para 10% de falsos positivos.

Experimento	Limiar	Global	Aleatórias	Habilidosas
1	L1	0,96303	0,995398	0,930662
	L2	0,957277	0,994241	0,920313
	L3	0,96137	0,994907	0,927833
2	L1	0,960421	0,994832	0,92601
	L2	0,954611	0,993574	0,915648
	L3	0,958616	0,994241	0,922992
3	L1	0,957145	0,993989	0,920301
	L2	0,952417	0,992417	0,912416
	L3	0,955932	0,993323	0,91854
4	RNA	0,926951	0,985053	0,868849
5	L1 (5% FP)	0,961603	0,995071	0,928135
	L2 (5% FP)	0,95563	0,993549	0,91771
	L3 (5% FP)	0,959632	0,994467	0,924796
	L1 (10% FP)	0,96225	0,995209	0,929292
	L2 (10% FP)	0,956447	0,993876	0,919018
	L3 (10% FP)	0,960487	0,994631	0,926343

Tabela 11 - AUC (área abaixo da Curva ROC) dos experimentos realizados.




Figura 21 - Comparativo entre os melhores casos dos experimentos realizados utilizando a base de dados I, no qual se destaca o primeiro experimento.

Para efeito comparativo com outras pesquisas na área, o sexto experimento utilizou a mesma configuração utilizada no primeiro experimento (melhor caso), porém utilizando a base de dados II, a qual foi disponibilizada no ICDAR 2011. Na Figura 22 pode-se visualizar a curva ROC do sexto experimento, a qual reportou o melhor caso também utilizando o limiar L1.




Figura 22 - Para o sexto experimento, tem-se de cima para baixo, a Curva ROC para os classificadores utilizando os limiares L1 (média), L2 (mediana) e L3 (média + mediana), respectivamente, utilizando a base de dados do ICDAR 2011.

A AUC dos classificadores utilizados no sexto experimento podem ser visualizadas na Tabela 12.

Experimento	Limiar	Global	Aleatórias	Habilidosas
6	L1	0,973293	0,998236	0,954586
	L2	0,964727	0,996473	0,940917
	L3	0,969766	0,996473	0,949735

Tabela 12 - AUC dos classificadores do sexto experimento utilizando a base do ICDAR 2011.

Em comparação com os resultados reportados pela competição de verificação de assinaturas *off-line* realizada no ICDAR 2011, os quais podem ser visualizados na Tabela 13, pode-se concluir que o experimento realizado obteve uma boa taxa de acerto, visto que seu FAR ficou em 19,44%, e a taxa de acerto (*Accuracy*) ficou em 85,86%, utilizando para isso, assinaturas genuínas e falsificações habilidosas.

SUBMITTED SYSTEMS	Accuracy(%)	FRR	FAR
Qatar University (Dutch optimization)	97.67	2.47	2.19
Qatar University (Chinese optimization)	95.57	4.48	4.38
Hong Duc University (HDU)	87.80	12.35	12.05
Sabancı University	82.91	17.93	16.41
Anonymous-1	77.99	22.22	21.75
German Research Center for Artificial Intelligence	75.84	23.77	24.57
Anonymous-2	71.02	29.17	28.79

Tabela 13 - Resultados da competição de verificação de assinaturas *off-line* realizada no ICDAR 2011 [Adaptado de LIWICKI, 2011].

O FAR global - utilizando assinaturas genuínas, falsificações habilidosas e falsificações aleatórias - do sexto experimento ficou em 9,72% e a taxa de acerto (*Accuracy*), nesse mesmo contexto, ficou em 88,89%.

5. Conclusão

Esta dissertação propôs a geração de uma base de assinaturas independente, como também a utilização do Coeficiente de Correlação de Pearson como característica discriminante no contexto da verificação de assinaturas. A base de dados do ICDAR 2011 também foi utilizada para comparar os resultados obtidos na primeira etapa.

Como fase inicial, foi gerada uma base de assinaturas com 1.410 exemplares, sendo 940 genuínas (geradas por 94 autores) e 470 falsificações habilidosas (geradas por 6 autores).

Na segunda etapa, a técnica de Correlação Pearson foi aplicada nas imagens para extração dos coeficientes, que, por sua vez, foram utilizados como características no contexto da verificação de assinaturas manuscritas *off-line*. Dentre as abordagens utilizadas, a primeira utilizou os limiares gerados a partir dos coeficientes para efetuar a classificação, e a segunda utilizou uma RNA para categorizar as assinaturas.

Nesse sentido, foram empregadas abordagens locais e globais. As primeiras obtiveram os melhores resultados, conforme foi reportado pelo primeiro experimento, que trouxe a melhor AUC Global dentre os classificadores utilizados. Isso se deve a forma como os limiares foram calculados para o primeiro experimento, efetuando um relacionamento com todas as assinaturas no conjunto de referência.

Como pode ser visualizado no sexto experimento, e comparando-o com trabalhos como o de Mélo [MÉLO, 2011], o qual também utilizou a mesma base de dados, nota-se uma melhora na taxa Global de Falsos Positivos, caindo para 9,72%, sem perder na taxa de Verdadeiro Positivo, a qual ficou em 88,89%.

Ainda analisando os resultados do sexto experimento, pode-se dizer que foram satisfatórios, quando comparados com os resultados apresentados pela competição de assinaturas do ICDAR 2011.

Os pontos negativos observados no decorrer do estudo foram os seguintes:

- Pouca disponibilidade de bases de assinaturas públicas;
- Ocorrência de assinantes com alta variação intrapessoal, prejudicando a geração de limiares mais consistentes;
- Falta de mecanismos para poder identificar outros tipos de falsificações;

Após a execução de todos os experimentos, pôde-se verificar que os objetivos traçados para esse projeto foram alcançados com sucesso, visto que as taxas de falsos positivos e verdadeiros positivos, respectivamente, foram reportadas dentro da média em relação aos trabalhos pré-existentes na área.

5.1 Trabalhos Futuros

Como sugestões para trabalhos futuros, podem-se destacar os seguintes tópicos:

- Utilizar outros classificadores, com base em uma abordagem local, a exemplo do KNN;
- Utilizar uma abordagem utilizando agrupamento de classificadores;
- Inserir outros tipos de características em conjunto com os coeficientes extraído pela fórmula de Correlação de Pearson;
- Na abordagem empregando uma RNA como classificador, utilizar para alimentar a rede no momento do treinamento, validação e teste, a média dos coeficientes entre a assinatura questionada e as assinaturas presentes em um conjunto de referência.

Ante todo o exposto, e observando-se o grau de satisfação da técnica de Correlação de Person, pode-se vislumbrar grandes possibilidades para

trabalhos futuros, com o aprimoramento das técnicas utilizadas e consequente diminuição progressiva das taxas de falso positivo, tornando a verificação *off-line* de assinaturas um método cada vez mais difundido na seara dos reconhecimentos automatizados.

Referências

- ABIKOYE, O. C.; MABAYOJE, M. A. and AJIBADE, R. **Offline Signature Recognition & Verification using Neural Network**. *International Journal of Computer Application*, 35(2): 44 – 51, 2011.
- AMARAL, Sylvio do. **Falsidade Documental**. 4ª Ed. Editora Millenium. Campinas, São Paulo. 2000.
- BANDYOPADHYAY, S. K.; BHATTACHARYYA, D. and DAS, P. **Handwritten signature recognition using departure of images from independence**. *3rd IEEE Conference on Industrial Electronics and Applications*, pages 964 – 969, 2008.
- BRAGA, A. P.; CARVALHO, A. C. P. L. F. e LUDERMIR, T. B. **Redes Neurais Artificiais: Teoria e Aplicações**, LTC, 2007.
- CARVALHO, J. V.; SAMPAIO, M. C. e MONGIOVI, G. **Utilização de Técnicas de “Data Mining” para o Reconhecimento de Caracteres Manuscritos**. XIV Simpósio Brasileiro de Banco de Dados, 1999.
- CHAUDHARY, S.; NATH, R. **A Multimodal Biometric Recognition System Based on Fusion of Palmprint, Fingerprint and Face**. *International Conference on Advances in Recent Technologies in Communication and Computing*, pages 596 – 600, 2009.
- COETZER, J. **Off-line Signature Verification**. *Phd thesis, University of Stellenbosh*, 2005.
- CUI, Bo; XUE, Tongze. **Design and Realization of an Intelligent Access Control System Based on Voice Recognition**. *ISECS International Colloquium on Computing, Communication, Control, and Management, CCCM*, 1: 229 – 232, 2009.
- DAGHER, I.; HELWE, W.; YASSINE, F. **Fingerprint recognition using fuzzy artmap neural network architecture**. *Microelectronics, The 14th International Conference - ICM*, pages 157 – 160, 2002.

DARAMOLA, Adebayo and IBIYEMI, Samuel. **Offline Signature Recognition using Hidden Markov Model (HMM)**. *International Journal of Computer Applications*, 10(2): 17–22, 2010.

DAUGMAN, J. **The Importance of Being Random: Statistical Principles of Iris Recognition**. *Pattern Recognition*, 36(2):279–291, 2003.

FANG, B., LEUNG, C., TANG, Y., KWOK, P., TSE, K., and WONG, Y. **Offline Signature Verification with Generated Training Samples**. *IEEE Proceedings-Vision, Image and Signal Processing*, 149(2):85–90, 2002.

FAWCETT, Tom. **ROC Graphs: Notes and Practical Considerations for Researchers**. *Kluwer Academic Publishers*, 2004.

FERREIRA, Denilson Palhares. **Identificação de Pessoas por Reconhecimento de Íris Utilizando Decomposição em Sub-Bandas e uma Rede Neuro-Fuzzy**. Dissertação de Mestrado, UNICAMP. Campinas, São Paulo. 1998.

GOMES, H. **Investigação de Técnicas Automáticas para Reconhecimento Off-line de Assinaturas**. Dissertação de mestrado, Universidade Federal de Pernambuco, 1995

GONÇALVES, Diego Bertolini. **Agrupamento de Classificadores na Verificação de Assinaturas Off-Line**. Dissertação de Mestrado, Pontifícia Universidade Católica do Paraná, Curitiba, 2008

HASNA, J. **Signature Recognition Using Conjugate Gradient Neural Networks**. *IEEE transactions on engineering, computing and technology*, Vol. 14, ISSN 1305-5313, 2006.

HEINEN, Milton Roberto e OSÓRIO, Fernando Santos. **Autenticação de Assinaturas Utilizando Algoritmos de Aprendizado de Máquina**. XXV Congresso da Sociedade Brasileira de Computação, páginas 702-711, 2005.

HOQUE, M. M.; RAHMAN, S. M. F. **Fuzzy Features Extraction from Bangla Handwritten Character**. *International Conference on Information and Communication Technology*, pages 72 – 75, 2007.

ICDAR, *International Conference on Document Analysis and Recognition 2011*. Disponível em: <http://www.icdar2011.org/>. Acesso em 10/01/2014.

ICDAR, *International Conference on Document Analysis and Recognition 2009*. Disponível em: <http://www.cvc.uab.es/icdar2009/index.html>. Acesso em 25/01/2014.

IRANMANESH, V.; AHMAD, S. M. S.; ADNAN, W. A.W.; et al. **Online Signature Verification Using Neural Network and Pearson Correlation Features**. *IEEE Conference on Open Systems*, pages 18 – 21, 2013.

JAIN, A. K.; GRIESS, F. D. and CONNELL, S. D. **On-line Signature Verification**. *Pattern Recognition*, vol. 35, no. 12, pp. 2963--2972, Dec 2002.

JIN, A.L.H.; CHEKIMA, A.; DARGHAM, J.A.; LIAU Chung FAN, L. C. **Fingerprint Identification and Recognition Using Backpropagation Neural Network**. *Student Conference on Research and Development, SCORed*, pages 98-101, 2002.

JUSTINO, E. **O Grafismo e os Modelos Escondidos de Markov na Verificação Automática de Assinaturas**. PhD thesis, Pontifícia Universidade Católica do Paraná. 2001.

JUSTINO, R.; EDSON, J.; BORTOLOZZI, F. and SABOURIN, R. **The Interpersonal and Intrapersonal Variability Influences on Off-line Signature Verification Using HMM**, *Proc. XV Brazilian Symp. Computer Graphics and Image Processing*, pp. 197-202, Oct, 2002

KEIT, T.; PALANIAPPAN, R.; RAVEENDRAN, P. and TAKEDA, F. **Signature Verification System using Pen Pressure for Internet and E-Commerce Applicatio**. *Proceedings of ISSRE, Organized by Chillarge Inc, USA*, 2001.

LIWICKI, M.; HEUVEL, C. E.; et al. **Signature Verification Competition for Online and Offline Skilled Forgeries (SigComp2011)**. *International Conference on Document Analysis and Recognition (ICDAR)*, pages 1480 – 1484, 2011.

MÉLO, L. A. **Utilização de morfismo como classificador para verificação de assinaturas Off-line**. Dissertação de Mestrado, Universidade Federal de Pernambuco, 2011.

MENDES, Lamartine Bizarro. **Documentoscopia**. 2ª Ed. Editora Millenium. Campinas, São Paulo. 2003.

NÁPOLES, Saulo Henrique L. de M. e ZANCHETTIN, Cleber. **Uso de Combinação de Reservoir para Verificação de Assinaturas Manuscritas Off-line**. VIII Encontro Nacional de Inteligência Artificial, 2011.

PLAMONDON, R. ***Designing an Automatic Signature Verifier Problem Definition and System Description***. *Computer Processing of Handwriting*, pages 3–20, 1990.

PLAMONDON, R and SRIHARI, S. N. ***On-line and Off-line handwriting recognition: A comprehensive survey***. *IEEE Trans. Pattern Anal. Mach Intell.*, 22(1): 63-84. 2000.

QUEIROZ, Francisco. ***Introdução à Psicologia da Escrita***. Centro de Estudos de Psicologia da Escrita. 2ª ed. Porto, Portugal: Lasra, 2005.

SANTOS, C.; JUSTINO, E.; BORTOLOZZI, F. and SABOURIN, R. ***An Off-line Signature Verification Method Based on the Questioned Document Expert's Approach and a Neural Network Classifier***. *International Workshop on Frontiers in Handwriting Recognition*, pages 498–502, 2004.

SOUZA, Milena Rodrigues Pinheiro. **Verificação de assinaturas off-line: uma abordagem baseada na combinação de distâncias e em classificadores de uma classe**. Dissertação de mestrado, Universidade Federal de Pernambuco, 2009.

ZHANG, D.; LU, G.; LI, W.; et all. ***Palmprint Recognition Using 3-D Information***. *IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews*, 39(5): 505 – 519, 2009.

ZHAO, Ming; CHUA, T. S. ***Markovian mixture face recognition with discriminative face alignment.*** *8th IEEE International Conference on Automatic Face & Gesture Recognition*, page 1-6, 2008.